Reporte: Preparación de los datos.

Por PINU

Adaptaciones de la metodología CRISP-DM..... 1
Reporte de limpieza de datos..... 2
Reporte de construcción e integración de datos..... 4
Integración del clima con las sesiones de ordeño.....4
Construcción de los atributos de temperatura.....4
Construcción de los atributos derivados..... 5
Construcción de los atributos de concentrado..... 9
Reporte de formato de datos..... 12
Investigar posibles modelos en base a los datos:..... 12
Reporte de selección del modelo..... 14
Técnica seleccionada de los modelos..... 14
Supuestos de los modelos..... 15
Técnica de modelado y comparación justa entre modelos..... 17
Ajustes a la preparación de los datos requeridos por los modelos..... 18
Reporte de selección de datos..... 19
Glosario de terminología..... 26
Fuentes bibliográficas..... 28

Adaptaciones de la metodología CRISP-DM

Se agregó una sección de glosario, con el fin de que cada interesado al proyecto pueda comprender todos los temas que se tratan dentro del mismo.

Se juntaron las secciones de reporte de construcción de datos con integración de datos, ya que para la construcción de ciertos atributos se requería juntar el conjunto de vacas con temperatura.

- Se revisaron los datos de todos los archivos para eliminar sesiones duplicadas entre ambos archivos y duplicados exactos en el mismo archivo.
- Las columnas con datos vacíos o constantes fueron eliminados pues la información que brindaban era nula.
- Se eliminaron las visitas de máquinas de ordeño con menos de 100 registros, debido a la escasez de observaciones y estas no dejan comparar nada relevante.
- Se eliminan las columnas originales de las categorías pues estas se vuelven dummies por lo que ya no son necesarias.

- ❖ Los registros con conductividad 0 son marcados con valor nulo, esto es debido a un error de registro pues es imposible que existe 0 en conductividad
- ❖ Los cuartos que produjeron 0, todos sus datos pasan a volverse 0 porque esto significa una anomalía en el registro.
- ❖ Los registros que tras el tratamiento de nulos no se completa el historial se eliminan ya que no tienen valor.
- ❖ Las vacas con registros menores a 30 son removidas debido a su poco impacto e historial.
- ❖ Los valores que tienen valores nulos se transforman en 0 y se levanta una bandera que indica qué variable faltó.
- ❖ En la limpieza de clima los valores duplicados y los códigos faltantes en valores nulos son removidos.

Reporte de limpieza de datos

Después de hacer el entendimiento de los datos se realizó una limpieza y preparación de los mismos con el objetivo de diseñar un modelo que cumpla el objetivo del mismo. Para el proceso de limpieza se realizaron diferentes acciones que permitieron tener datos estandarizados y con ello permitir que el modelo pueda aprender de los mismos.

Como primera acción fue estandarizar las columnas a minúsculas y separación estilo *“Snake_case”*, así mismo para las columnas categóricas se declararon casos base, principalmente para evitar casos de multicolinealidad, los casos base son los siguientes: “main_accion”: Ordeño, "misc_eo_po": None, "misc_destino_leche": "Tanque", "misc_razon_de_la_desviacion": "Sin desvío", "fuente": "xlsx".

Lo siguiente que se estandarizó fue el formato de fecha y las columnas de duración e intervalo. El formato de fecha elegido fue *DD/MM/AAAA* así como la medida de tiempo de la columna de duración fue de segundos, esto por comodidad y facilidad para transformarlo en minutos y segundos. La medida de intervalo es en horas ya que esta es la que mide el tiempo entre ordeño de la misma vaca, para esta mínimo tienen que pasar alrededor de 6 horas, en el caso de que pasen más de 48 horas, el registro se marcará con una bandera para facilitar su identificación.

Para los registros se tenían dos tipos de archivo en la fuente original, estos dos tipos de archivo son *“.csv”* y *“.xslx”*, de estos archivos 7,249 filas son de .csv y 278,968 son de .xlsx. Algunos de estos registros coinciden entre archivos por lo que cuentan como duplicados así mismo en los mismos archivos hay duplicados exactos. Estos registros repetidos son eliminados con el objetivo de tener registros únicos y poder entrenar el modelo de forma efectiva. También se eliminó la columna “estado_rcs_1000_celulas_ml” que se encontraba vacía y no aportaba datos, así

como las columnas con valores constantes “misc_usuario” y “misc_programa_de_lavado” que reportaron el mismo valor a lo largo de los registros o valores nulos.

Las alertas de texto fueron convertidas en banderas que indican en qué cuarto de la ubre de la vaca ocurrió la incidencia, es decir, que si la máquina de ordeño no llegara a encontrar el cuarto delantero izquierdo (DI) la columna correspondiente marcaría un valor 1, de lo contrario estas columnas deben ser 0.

Para el tratamiento de valores nulos e inconsistencias se revisó primero los registros con un valor de conductividad igual a 0, esto no puede ser posible en un caso real por lo que se trata de un registro mal capturado, para evitar problemas con la serie de tiempo estos datos se registran como nulos. El resto de valores nulos se tratan de imputar usando la mediana de la misma vaca, en el caso de que un registro haya sido imputado se levanta una bandera en la que se indica que valor era el faltante para poder identificarlo rápidamente. También se marcan los registros que la suma de producción de los cuartos de ubre no sean iguales al total o que el ordeño sea de 0 kg, estos son una captura errónea de los datos.

En cuanto a los indicadores de sangre se identificó que el límite de registro es de 8,000 ppm, por lo que cantidades que se acerquen mucho a dicha cantidad, por ejemplo 7,000 ppm, son marcadas con una bandera. Se dejó la medición de partes por millón (ppm) en las columnas de sangre, también se identifica la frecuencia de detección en los últimos 30 días y se marcan los picos de sangre por máquina.

Se aplicó una transformación logarítmica a las columnas con variables de sangre y MDI que tenían distribuciones asimétricas para reducir el efecto de los valores extremos, conservar los ceros y mantener todos los registros sin necesidad de eliminar los valores atípicos. También se realizó una limpieza a los datos obtenidos de *“NASA POWER”*, se eliminaron los duplicados y se revisó por valores faltantes que la fuente registra como -999, afortunadamente los datos se encontraron completos. Se generó una rejilla horaria completa, se limitó los valores de humedad y nubosidad a rangos aceptables y se integraron las columnas a los datos de las vacas.
Finalmente los datos nulos se convirtieron en 0 para no tener que eliminarlos, de esta forma generando el nuevo set de datos estandarizado y procesado para poder trabajar de forma correcta las propuesta de modelo de la siguiente etapa.

Reporte de construcción e integración de datos

Integración del clima con las sesiones de ordeño
La serie horaria de NASA POWER (31,104 horas, del 13/07/2022 al 28/01/2026, en hora local de Ciudad de México) se unió a la tabla de sesiones mediante la fecha y

hora de inicio de cada ordeño. Antes de la unión se corrigió un desfase: la fila que NASA POWER etiqueta con la hora *t* describe el clima de *t* + 1 h (se confirmó comparando la serie con una estación meteorológica observada, cuya correlación horaria de temperatura sube de 0.884 a 0.943 con la corrección). Por eso la serie se corre una hora hacia adelante al leerla; el archivo descargado no se modifica.

Después, la hora de inicio de cada sesión se redondea hacia abajo a la hora completa y se une con la fila de clima de esa hora (unión por la izquierda, de modo que no se pierde ninguna sesión). Con esta regla, el 100 % de las sesiones quedan con clima.

Construcción de los atributos de temperatura

Índice de temperatura-humedad (THI). Se calcula por hora a partir de la temperatura a 2 m (T, en °C) y la humedad relativa (HR, en %):

$$\mathrm{THI} = (1.8 \cdot T + 32) - (0.55 - 0.0055 \cdot \mathrm{HR}) \cdot (1.8 \cdot T - 26)$$

Se usa como medida principal del estrés calórico porque combina la temperatura y la humedad en un solo valor. Se toma 68 como umbral de THI alto. En el periodo, el 21.8 % de las horas y el 21.2 % de las sesiones ocurren con THI ≥ 68.

Atributos construidos.

Atributo	**Nivel**	**Construcción**
t_sesion	Sesión	Temperatura de la hora en que inicia la sesión
thi_sesion	Sesión	THI de la hora en que inicia la sesión
horas_thi_alto_24h	Sesión	Número de horas con THI ≥ 68 en las 24 horas previas (acumulación de calor)

Las ventanas se calculan siempre hacia atrás desde el inicio de la sesión. Así, el modelo solo usa clima que ya ocurrió cuando la vaca entra al robot, que es lo que tendría disponible una alerta temprana. Un resumen del día natural completo, como el THI máximo del mismo día, incluiría horas posteriores al ordeño y por eso no se usa como predictor.

Justificación.
En el entendimiento de los datos, el efecto del calor sobre la producción fue pequeño pero detectable: en días con THI máximo ≥ 68 la producción relativa de cada vaca baja entre 1.0 y 1.1 puntos porcentuales, y la correlación del hato con el THI medio se mantiene similar con rezagos de 0 a 5 días (Spearman de −0.11 a −0.14). La tasa de patadas sube de 15.1 % con THI menor a 55 a 17.6 % con THI de 68 o más. Las horas acumuladas distinguen un pico breve de calor de una exposición prolongada. Como la temperatura y el THI están casi perfectamente correlacionados (r = 0.99), en el modelado conviene elegir entre ellos y no usar ambos.

Valores faltantes.
La serie de clima cubre todo el periodo sin huecos. Solo 7 sesiones (13/07/2022, antes de la 01:00) no tienen clima de su hora por el desfase de una hora, y 78 (0.03 %) no completan las 24 horas previas. Se dejan como faltantes, sin rellenar.

Limitaciones.
El clima es de exterior y representa una celda de ½° × ⅝° (≈ 55 × 65 km), por lo que no mide el microclima del establo. Además, el desfase de una hora se midió contra una sola estación.

Construcción de los atributos derivados

Índice de presión de moscas: Se calcula combinando variables ambientales, por ejemplo la temperatura del ambiente, variables temporales como una variable lógica para conocer si es tarde (entre 1pm y 5pm) y el historial de patadas de las vacas.

$$Flies_proxy \;=\; es_tarde \;\cdot\; T_{ambiente} \;\cdot\; tasa_historica_patadas_{vaca}$$

Eventos fallidos de ordeño (Fail milking events FME): Se toman en cuenta las columnas que tenemos de estado_incompleto, estado_pezones_no_encontrados y los flujos por cuarto para denotar anomalías en la conexión a las vacas, producción de leche y estado del ordeño.

$$FME_connection \;=\; estado_pezones_no_encontrados \,!=\; 0$$

$$FME_milk_production = producciones_kg_dd,\, di,\, td,\, ti \;=\; 0$$

$$FME__incomplete \;=\; estado_incompleto \,!=\; 0$$

Severidad e intensidad de patadas: se construye a partir de la columna de estado_patada, es una proporción entre el número de cuartos afectados por patada y el número de ordeños totales para una vaca.

$$kicks_ratio_7d = \frac{num_cuartos_patada}{ordeños_totales_7d}$$

Detección de sangre en leche: Se construye utilizando la columna de sangre en partes por millón de cada cuarto, y se obtiene la desviación de sangre por cada cuarto respecto al valor promedio de la sangre en partes por millón.

$$Blood_diff_di, dd, ti, td = sangre_ppm_di,\ dd,\ ti,\ td - media_sangre_ordeño_{vaca}$$

Eficiencia de ordeño y estadía en la máquina: Representa la proporción de la duración del ordeño expresado en minutos contra la producción en kilogramos de leche.

$$box_time_to_yield_ratio = \frac{main_duracion_mm_ss}{main_produccion_kg}$$

Clasificación de los eventos de ordeño: Se consideran 4 tipos de eventos, fallo mecánico o de conexión, anomalía de salud, interrupción por conducta y ordeño exitoso, que actuaran como las respuestas que debe predecir el modelo, se calculan utilizando las observaciones presentes en los datos.

Atributos construidos.

Atributo	**Nivel**	**Construcción**
Flies_proxy	Sesión e histórico de la vaca	hora a la que inicia la sesión, temperatura a la que inicia la sesión e histórico de patadas de la vaca.
FME_connection	Sesión previa	Si existe presencia de cualquier pezón no encontrado en el ordeño previo.
FME_milk_production	Sesión previa	Existe alguna producción de leche por cuarto que es igual a 0 en la sesión previa.
FME_incomplete	Sesión previa	El ordeño previo tiene un estado incompleto.

Atributo	**Nivel**	**Construcción**
Kicks_ratio_7d	Semana previa	Proporción entre el número de cuartos de leche afectados por una patada respecto al número de ordeños totales en los 7 días previos.
Blood_diff_di,dd,ti,td	Sesión previa	La diferencia de sangre por cuarto respecto a la media de sangre de los cuartos en el ordeño previo.
Box_time_to_yield_ratio	Sesión previa	Proporción entre el tiempo en minutos que dura una vaca en el ordeño, respecto a la producción de leche
Evento de falla mecánica o conexión	Sesión	Pezones no encontrados diferente de nulo. Producción de un cuarto de leche igual a 0. Estado del ordeño marcado como incompleto.
Evento de anomalía de salud	Sesión	Presencia de sangre en leche superior en algún cuarto de leche. Estado mdi, amd de ubre o amd de pezón diferentes de nulo.
Evento de interrupción por conducta	Sesión	Estado de patadas diferente de nulo.
Evento de ordeño exitoso	Sesión	Si los 3 estados anteriores se encuentran marcados como que no ocurrieron (0)

Justificación.
Las moscas de los establos y de los cuernos aumentan su población y actividad significativamente más por la tarde o con temperaturas superiores a los 15°C, esto puede ocasionar eventos como patadas, sacudidas de cuerpo, coletazos o espasmos en la piel de las vacas, lo que puede dificultar el acoplamiento de los pezones al momento de extraer la leche. Perttu, R. K., Heins, B. J., Phillips, H. N., Endres, M. I., Moon, R. D., & Sorge, U. S. (2020).

Los eventos de ordeño fallido (FME) representan una pérdida operativa directa. El 35.1% de las fallas se deben a tiempos de conexión prolongados (CT), el 21.9% a múltiples intentos fallidos de acoplamiento, y el 35.4% a leche muerta (DT). Neupane, R., Ceja, G., Daigle, C., Tedeschi, L. O., Khanal, P., Valeris-Chacin, R., Xu, Z., & Paudyal, S. (2026). Hernández-Gotelli, C., & Pinedo, P. J. (2026).

La presencia de sangre en leche es una anomalía fisiológica aguda asociada a trauma en el pezón y/o ubre, lesiones vasculares o procesos inflamatorios severos, siendo un predictor clave en modelos de detección de anomalías de leche. Fan, X., Watters, R. D., Nydam, D. V., Virkler, P. D., Wieland, M., & Reed, K. F. (2023).

Las vacas enfermas pasan más tiempo en el cajón del robot pero producen menos leche, elevando este ratio de forma muy consistente frente a vacas sanas. Hernández-Gotelli, C., & Pinedo, P. J. (2026).

Estos valores pueden utilizarse como atributos para predecir los eventos clasificados descritos.

Valores faltantes.
Existen valores faltantes en varias columnas de nuestros datos que se utilizan para construir estos atributos, por ejemplo valores faltantes en patadas, presencia de sangre, estado del ordeño, etc. Pero estos valores representan que el ordeño sucedió de forma correcta, únicamente necesitan adaptarse conforme lo requiera el modelo.

Limitaciones.
Como el objetivo de minería de datos es clasificar los posibles tipos de evento que se presenta en el ordeño, no podemos utilizar las variables del ordeño actual, sino que tienen que tener un desfase temporal (lagged features), ventanas móviles (rolling windows) y depender de predicciones para las variables de temperatura y tiempo de ordeño. Fan, X., Watters, R. D., Nydam, D. V., Virkler, P. D., Wieland, M., & Reed, K. F. (2023). Kashongwe, O., Kabelitz, T., Ammon, C., Minogue, L., Doherr, M., Silva Boloña, P., Amon, T., & Amon, B. (2024).

Por ejemplo se utilizarían los datos del ordeño previo, para FME_connection, FME_milk_production, FME_incomplete, num_cuartos_patada, Blood_diff_di,dd,ti,td

y box_time_to_yield_ratio. Una ventana deslizante para el cálculo de kicks_ratio_7d, donde se utilizará el registro de la semana previa al ordeño y las predicciones del clima o del horario en que realizará el ordeño la vaca.

Construcción de los atributos de concentrado

La tabla de concentrado tiene 129532 registros de 202 vacas, del 28/01/2025 al 28/01/2026, con un solo tipo de alimento.

Según el socio formador, cada registro es la cantidad en kilogramos que una vaca come dentro del robot durante una sesión, donde el concentrado se ofrece como incentivo. El robot asigna a cada vaca una cantidad que se acumula con el tiempo desde su visita anterior y se la sirve poco a poco mientras se ordeña, lo que evita que una vaca coma la ración de otra.

La tabla se une a las sesiones por id_vaca, que se anonimiza con la misma llave que la tabla de ordeño. De las 207 vacas con sesiones, 201 tienen registros de concentrado, y las 6 restantes quedan sin estos atributos. Antes de calcular los atributos se deben eliminar también los 5 registros duplicados de la tabla de concentrado para no contar dos veces el mismo consumo.

Los registros están a la hora en punto, pero se pueden vincular a su sesión. Para ello, la hora de inicio de cada sesión se puede redondear hacia abajo a la hora completa (H), como se hace en la integración del clima. El 92.1% de los registros cae en la misma hora H que exactamente una sesión de la vaca, y otro 5.9% en la hora siguiente. Por lo tanto, el registro de la hora H es el consumo de la misma sesión que se quiere predecir, y como ese dato solo se conoce al terminar la sesión, no se usa como predictor. Todos los atributos usan solo registros anteriores a H.

Atributos construidos

Atributo	Nivel	Construcción
conc_sesion_previa	Sesión previa	Kg consumidos en la sesión anterior de la vaca
tope_sesion_previa	Sesión previa	1 si en su visita anterior la vaca comió el máximo observado de 2.5 kg o más, 0 si no
conc_d1	Sesión	Kg consumidos en el día natural anterior a la fecha de la sesión
conc_media_7d	Sesión	Promedio diario de kg consumidos en los 7 días naturales anteriores

Todas las ventanas terminan en el inicio de la sesión, para que el modelo solo use registros de consumo que ya ocurrieron cuando la vaca entra al robot. Por eso no se usa el consumo del mismo día natural, pues incluiría horas posteriores al ordeño.

Justificación.

En el EDA de concentrado y producción, el consumo diario de concentrado y la producción diaria de leche tuvieron una correlación de 0.585 en 49981 días vaca (días con registros tanto de ordeño como de concentrado). Al restar el promedio de cada vaca, la correlación sube a 0.655, y calculada por separado tiene una mediana de 0.677 en 200 vacas. Es decir, cuando una vaca come más de lo normal para ella, también produce más de lo normal. Por eso se incluye conc_media_7d, que resume cuánto ha comido normalmente cada vaca en la última semana.

El socio formador confirmó que el concentrado se ofrece dentro del robot como incentivo, como es común en los sistemas de ordeño voluntario (Schwanke et al., 2019), y que cada registro es la cantidad en kilogramos que la vaca consume en una sesión. Por lo tanto, el consumo diario crece con el número de visitas al robot, y la relación del mismo día con la leche puede deberse en buena parte a que una vaca que va más veces come y produce más. Para separar ambos efectos se usa conc_sesion_previa, que mide cuántos kilogramos comió la vaca en una sola visita, sin importar cuántas veces fue al robot. En los datos, el consumo diario aumenta con el número de registros del día (mediana de 1.40 kg con uno a 4.66 kg con seis), mientras que los kilogramos por registro disminuyen (de 1.40 a 0.78 kg).

El consumo por sesión aumenta con el tiempo desde la visita anterior de la misma vaca, pues la mediana pasa de 0.51 kg cuando regresa antes de 4 horas a 1.56 kg entre 16 y 24 horas. Esto es consistente con que el robot asigne a cada vaca una cantidad que se acumula con el tiempo, como en otros sistemas de alimentación de robots (Langlois, 2023). No hay evidencia de que una vaca coma el sobrante de la anterior, ya que su consumo apenas se relaciona con el de la vaca que entró antes en la misma máquina, y los pocos consumos de más de 2.5 kg ocurren después de vacas que comieron más, no menos. El consumo por sesión tiene un tope aparente de 2.5 kg pues el histograma se corta en ese valor, además, 2.5 kg es uno de los consumos más frecuentes, con 1972 registros, y el 99% de los consumos es de 2.497 kg o menos. Llegar al tope es más frecuente tras intervalos largos (12.7% entre 16 y 24 horas contra menos de 1% antes de 12 horas) y en sesiones largas (6.07% en las de más de 12 minutos). Por eso se incluye tope_sesion_previa, que indica si en su visita anterior la vaca comió el máximo observado. Después de esas visitas, la tasa de ordeño incompleto es 6.1 puntos porcentuales mayor y la de pezón no encontrado 4.1 puntos mayor; sin embargo, solo el 1.7% de las sesiones cumple esta condición, y al comparar a cada vaca consigo misma, la asociación casi desaparece.

La relación entre el concentrado del día anterior y la producción del día actual es débil (r = 0.221, mediana por vaca de 0.068), mucho menor que la del mismo día, así que se espera poco peso de conc_d1. Estos atributos construidos ayudan a explicar las alertas al personal, pero el análisis llevado a cabo solo demuestra asociaciones, por lo que los atributos deberán presentarse como factores asociados y no como causas del evento.

Valores faltantes.

De las 122788 sesiones dentro del periodo de concentrado, el 97.8% tiene registros el día anterior (conc_d1), el 96.9% tiene el consumo de su sesión anterior ligado a esa sesión (conc_sesion_previa y tope_sesion_previa) y el 93.1% tiene registros en los 7 días previos completos (conc_media_7d). Cuando una ventana está incompleta o no tiene registros, el atributo se deja como faltante y no se rellena, igual que en los atributos de temperatura. Tampoco se cuenta como consumo cero, al no saberse si la vaca no comió o si simplemente el consumo no se registró. conc_sesion_previa y tope_sesion_previa también quedan como faltantes cuando el registro de la sesión anterior no se pudo ligar a una sola sesión. Por último, quedan sin ningún atributo de concentrado las sesiones anteriores al 28/01/2025 y las de las 6 vacas sin registros.

Limitaciones.

- La hora de los registros está redondeada a la hora completa, por lo que una parte de los registros no se puede ligar a una sola sesión.
- El concentrado cubre solo un año del historial, así que las sesiones de 2022 a 2024 no tendrán estos atributos.
- La columna consumido_mat_seca es idéntica a consumido (la proporción entre ambas es 1.0 en todos los registros), aunque el socio formador indicó que el alimento tiene 88% de materia seca. Es por eso que no se usa, y si se necesitara la materia seca se calcularía como consumido * 0.88.
- Los registros indican el concentrado consumido, no el servido, y no se sabe cuánto alimento hay en el comedero en cada visita. Falta confirmar con el socio formador si el tope de 2.5 kg es un límite configurado en el robot y por qué existen algunos consumos mayores, como uno de 4.715 kg.

Reporte de formato de datos

Investigar posibles modelos en base a los datos:

En base a los datos que tenemos y el objetivo que buscamos lograr se definieron los siguientes posibles modelos para dar una solución:

1. N Regresión Logística Regularizada (donde N es igual al número de eventos):
    a. **Razón:** la relación más fuerte en los datos es simple: un evento previo multiplica de 3.3 a 4.5 veces la probabilidad del siguiente, un efecto

que la regresión logística representa directamente. Se entrena una regresión logística binaria por evento, porque los eventos pueden ocurrir juntos.

   b. **Beneficio:** muy interpretable; cada coeficiente se lee como un *odds ratio*, lo que da directamente los 3 factores por alerta. Sus probabilidades salen bien calibradas y es estable con variables correlacionadas gracias a la regularización.
   c. **Riesgo:** solo capta relaciones lineales; las interacciones (por ejemplo, intervalo corto con evento previo) hay que crearlas a mano. Requiere escalar variables y manejar los nulos antes de entrenar.
   d. **Tamaño:** unos 20 pesos por evento; entrena en segundos y su ajuste es el más barato (sólo la fuerza de regularización).

2. XG Boost
   a. **Razón:** Parecido al random forest pero ayuda a corregir errores ocasionados por sus contrapartes.
   b. **Beneficio:** captura no linealidades e interacciones sin prepararlas, maneja nulos de forma nativa y explica cada alerta con SHAP de forma rápida y exacta.
   c. **Riesgo:** sobreajuste si no se usa *early stopping* con validación cronológica. Requiere ajustar varios hiperparámetros (profundidad de los árboles, tasa de aprendizaje, número de árboles, muestreo de filas y variables, y regularización), lo que implica entrenar y comparar muchas combinaciones.
   d. **Tamaño:** cientos de árboles pequeños (unos MB); entrena en segundos o pocos minutos por evento y su ajuste tiene costo moderado.
3. Random Forest
   a. **Razón:** funciona bien casi con la configuración por defecto y tolera variables de cola larga y atípicos, que en los datos no se eliminan porque pueden ser las anomalías buscadas.
   b. **Beneficio:** al promediar muchos árboles es robusto frente al sobreajuste, requiere poco ajuste y sirve como punto de comparación para validar a XG Boost.
   c. **Riesgo:** sus probabilidades salen mal calibradas (requiere calibración aparte para mostrarlas por alerta); la importancia de variables por defecto se sesga con variables correlacionadas, como temperatura y THI (0.99), y los árboles profundos pueden memorizar a cada vaca.
   d. **Tamaño:** el más pesado en memoria, de cientos de MB a más de 1 GB con árboles profundos; entrena en minutos y predice más lento que XGBoost.
4. Red Neuronal Densa con n neuronas de salida.
   a. **Razón:** una sola red con una salida sigmoide por evento aprende a la vez los n eventos y comparte lo aprendido entre ellos, lo que

aprovecha que el incompleto y el pezón no encontrado coinciden en 79 a 80% de los casos.

b. **Beneficio:** aprende no linealidades por sí sola y resuelve todos los eventos en un solo modelo (multitarea).
c. **Riesgo:** es difícil de explicar a un socio no técnico, porque los 3 factores por alerta solo se obtienen con SHAP, que es lento en redes. Sin regularización (*dropout*, *weight decay*, *early stopping*) tiende a sobreajustar, y conviene revisar la calibración de sus probabilidades. Si se usan muchas capas con activaciones sigmoide, puede presentar desvanecimiento del gradiente; se evita con activaciones ReLU y pocas capas ocultas.
d. **Tamaño:** pequeña en disco (miles de pesos, KB), pero la más cara de entrenar y ajustar: varias épocas por prueba y muchas combinaciones de capas, neuronas, tasa de aprendizaje y *dropout*.

5. Red Neuronal Recurrente (GRU o LSTM) con n neuronas de salida
    a. **Razón:** los datos de cada vaca forman una secuencia de ordeños en el tiempo. Una red recurrente recibe las últimas k sesiones de la vaca (por ejemplo 10 a 20) y aprende por sí sola qué parte del historial importa, en lugar de depender de rezagos y ventanas construidos a mano. Este enfoque se ha usado para detectar mastitis con datos de ordeño robotizado como series de tiempo multivariadas (Fan et al., 2023).
    b. **Beneficio:** captura patrones temporales y no lineales sin definir de antemano el tamaño de las ventanas ni las interacciones. Con una salida sigmoide por evento resuelve todos los eventos en un solo modelo (multitarea). El clima y el concentrado de la sesión actual pueden agregarse después de la capa recurrente como contexto.
    c. **Riesgo:** los intervalos entre ordeños son irregulares, así que hay que agregar el tiempo transcurrido desde la sesión anterior como variable. Con unas 207 vacas puede memorizar el patrón de cada una, por lo que requiere validación cronológica. Es el modelo más difícil de explicar a un socio no técnico, porque los 3 factores por alerta deben atribuirse a una variable y a una sesión pasada específica. Además, sus probabilidades pueden requerir calibración y no hay garantía de que supere a XGBoost con rezagos bien construidos.
    d. **Tamaño:** pequeña en disco (decenas de miles de pesos, KB a pocos MB), pero la más cara de entrenar y ajustar. Requiere preparar las secuencias (relleno, normalización) y probar combinaciones de longitud de ventana, unidades, capas, dropout y tasa de aprendizaje, con varias épocas por prueba.

Reporte de selección del modelo

De los cinco modelos propuestos se eligieron tres, uno por familia (lineal, ensamble de árboles y redes neuronales), para saber si la relación entre variables y eventos es casi lineal, si hay interacciones que capturan mejor los árboles y si la secuencia de ordeños de cada vaca aporta información adicional.

Regresión logística regularizada: es la línea base. En 282 comparaciones justas, diferentes modelos de machine learning no la superaron (Christodoulou et al., 2019), y con datos de ordeño robotizado seis modelos, incluida la regresión logística, obtuvieron AUC de 0.80 a 0.84 al predecir mastitis un día antes (Dharejo et al., 2025). Da probabilidades calibradas y coeficientes para explicar cada alerta.

XGBoost en lugar de Random Forest: ambos son ensambles de árboles y el boosting suele igualarlo o superarlo en datos tabulares (Grinsztajn et al., 2022). Además maneja nulos sin imputar y calcula SHAP de forma exacta.

LSTM en lugar de la red densa: con datos de ordeño robotizado, una red densa con promedios de dos semanas obtuvo un AUC de 67.8 a 76.6 %, similar a la regresión logística, y la LSTM, que lee la secuencia de ordeños, de 81.6 a 84.1 % (Zhu et al., 2026).

Técnica seleccionada de los modelos

1. Regresión Logística Regularizada
    a. Una regresión logística binaria por tipo de evento, porque un ordeño puede tener varios a la vez, con regularización elastic net y solo información previa a la sesión. No se usan pesos por clase ni SMOTE, porque inflarían las probabilidades; el desbalance se maneja eligiendo el umbral de alerta según la sensibilidad buscada. Herramienta: scikit-learn.
2. XG Boost
    a. Un clasificador binario por evento con las mismas variables; cada árbol corrige los errores de los anteriores. Se ajustan profundidad, tasa de aprendizaje y número de árboles con early stopping. Los 3 factores salen de TreeSHAP: para cada ordeño calcula cuánto sumó o restó cada variable a la predicción (en log-odds), de modo que un valor base más la suma de las contribuciones da exactamente la salida del modelo; las contribuciones se ordenan y se reportan las 3 que más subieron el riesgo, junto con el valor de cada variable en ese ordeño. Herramienta: xgboost y shap.
3. LSTM
    a. Red multitarea que recibe las últimas k sesiones de la vaca (k de 10 a 30), con una salida sigmoide por evento más una para "alguna anomalía" y las horas desde el ordeño anterior en cada paso. Cada paso contiene las mismas variables por sesión que usan la regresión logística y XGBoost. Herramienta: TensorFlow/Keras.

Supuestos de los modelos

1. Regresión Logística Regularizada
    a. **Independencia de las observaciones**
        i. **Qué supone:** cada ordeño no depende de los demás.

ii. **Por qué importa:** los ordeños de una misma vaca se parecen (un evento previo multiplica de 3.3 a 4.5 veces el siguiente); si se ignora, los intervalos de confianza salen más estrechos de lo real.
iii. **Cómo se trabaja:** se agregan variables que resumen lo que le pasó a la vaca antes, por ejemplo si tuvo patada en el ordeño anterior o cuántas patadas tuvo en los últimos 7 días (kicks_ratio_7d). Al evaluar el modelo, se separa por fecha, para que el modelo se pruebe con ordeños posteriores a los de entrenamiento y no con ordeños casi iguales a los que ya vio, y los intervalos de confianza de los coeficientes se reportan como aproximados.

b. **Relación lineal con el logit**
   i. **Qué supone:** cada variable sube o baja el riesgo (en escala log-odds) siempre en la misma cantidad por unidad, sin importar si el valor es chico o grande; por ejemplo, pasar de 4 a 5 h de intervalo pesaría lo mismo que pasar de 20 a 21 h.
   ii. **Por qué importa:** muchos efectos reales no son parejos. La sangre es 0 en más del 75 % de los ordeños y llega a 8,000 ppm, y no es lo mismo pasar de 0 a 100 ppm que de 7,900 a 8,000 ppm. Con una sola recta, el modelo se equivoca en los valores bajos o en los altos.
   iii. **Cómo se trabaja:** se aplica logaritmo a las variables muy cargadas a un lado (como box_time_to_yield_ratio y la producción de la sesión previa) para que los cambios en valores bajos pesen más que en valores altos. Las variables con forma de U o con umbrales claros se agrupan en rangos (días en leche en 7 rangos y días en hato en 5), y los efectos que solo aparecen juntos, como intervalo corto con evento previo, se agregan como una variable nueva.

c. **Sin multicolinealidad**
   i. **Qué supone:** las variables no son casi copias unas de otras.
   ii. **Por qué importa:** los coeficientes se vuelven inestables y los 3 factores de cada alerta dejan de ser confiables; temperatura y THI tienen r = 0.99.
   iii. **Cómo se trabaja:** se deja solo thi_sesion y se quita t_sesion del conjunto de la regresión logística; la regularización L2 reparte el peso entre las demás variables correlacionadas.

d. **Escala común y sin nulos**
   i. **Qué supone:** las variables están en escalas comparables y no hay valores faltantes.
   ii. **Por qué importa:** la penalización trata distinto a una variable en ppm que a una en mS/cm, y la implementación no acepta nulos (el MDI tiene 8.4 % y la conductividad en 0 llega a 28.3 %).

iii. **Cómo se trabaja:** se estandariza con parámetros del entrenamiento y se imputa con la mediana de la vaca, más una bandera de faltante.

2. XG Boost
    a. **Sin supuestos de forma ni escala**
        i. **Qué supone:** nada sobre linealidad, normalidad o escala; solo corta las variables en umbrales.
        ii. **Por qué importa:** las variables asimétricas y los atípicos, que no se eliminan porque pueden ser las anomalías buscadas, no afectan al modelo.
        iii. **Cómo se trabaja:** se usan sin transformar.
    b. **Nulos consistentes**
        i. **Qué supone:** un nulo siempre significa lo mismo, porque el modelo aprende hacia qué rama enviarlo.
        ii. **Por qué importa:** las alertas nulas significan "no ocurrió", pero la conductividad en 0 es un sensor sin lectura; dejada como 0, se lee como una conductividad bajísima.
        iii. **Cómo se trabaja:** las alertas ya están como 0/1 y la conductividad en 0 se pasa a NaN.
    c. **Misma distribución en entrenamiento y prueba**
        i. **Qué supone:** los patrones del pasado se repiten en el futuro.
        ii. **Por qué importa:** los árboles no extrapolan: si en el futuro aparece un valor más alto que cualquiera del entrenamiento, por ejemplo más vacas por máquina, lo tratan como el más alto que conocen. Esto puede pasar porque el hato creció de 34 a 182 vacas activas por mes con las mismas máquinas y hubo fallas de sensores.
        iii. **Cómo se trabaja:** se prefieren variables relativas a la propia vaca en lugar de valores absolutos, por ejemplo el intervalo actual comparado con el intervalo promedio de esa vaca, para que los valores nuevos caigan en rangos que el modelo ya conoce. Además, se marcan con una bandera los periodos con sensores fallando y el modelo se reentrena periódicamente con los datos más recientes. En la prueba cronológica se revisa si variables de carga como vacas_activas_7d toman valores fuera del rango visto en entrenamiento.

3. LSTM
    a. **Secuencias con pasos equivalentes**
        i. **Qué supone:** la red recibe los k ordeños previos ordenados por fecha y trata cada paso igual.
        ii. **Por qué importa:** hoy hay un ordeño por fila y los intervalos van de 0.01 a 47.9 h; para la red, un ordeño 4 h después y otro 40 h después serían simplemente "el siguiente".

iii. **Cómo se trabaja:** se construyen las secuencias, se agregan las horas desde el ordeño anterior y la secuencia se reinicia tras 45 días sin registros.

b. **Historial suficiente y entradas limpias**
   i. **Qué supone:** cada muestra tiene k ordeños previos, escalados y sin nulos.
   ii. **Por qué importa:** 3 vacas tienen menos de 30 registros y los primeros ordeños de cada vaca no tienen el historial completo.
   iii. **Cómo se trabaja:** se excluyen esas vacas, las secuencias cortas se rellenan con máscara y se usa la misma estandarización e imputación que la regresión logística.

c. **Datos suficientes y patrones estables**
   i. **Qué supone:** hay suficientes ejemplos independientes y los patrones no cambian con el tiempo.
   ii. **Por qué importa:** con solo 207 vacas la red puede memorizar a cada una, y el crecimiento del hato puede cambiar los patrones.
   iii. **Cómo se trabaja:** pocas capas, dropout, early stopping y prueba en un periodo posterior al de entrenamiento.

Técnica de modelado y comparación justa entre modelos

Se registra como técnica la clasificación binaria multietiqueta con información previa a la sesión, probada en orden de complejidad: regresión logística, XGBoost y LSTM. Cada técnica tiene un modelo por tipo de evento y uno adicional para "alguna anomalía" (lo contrario de successful_milking_event), que da directamente la probabilidad de que el ordeño no sea exitoso y sus 3 factores, como pide el requerimiento del BU. Las probabilidades por evento no se suman, porque un ordeño puede tener varios eventos y se contaría dos veces. Se aplica con Python, los equipos con GPU y Google Colab del inventario.

Para que la comparación sea lo más justa posible, los tres modelos usan la misma información de entrada: las mismas variables de las sesiones previas, que la regresión logística y XGBoost reciben como rezagos y ventanas y la LSTM como secuencia. La LSTM recibe la secuencia de las k sesiones previas, y en cada paso las mismas variables por sesión (como conductividad máxima, MDI y producción) que la regresión logística y XGBoost reciben de la sesión previa. Las mediciones crudas por cuarto no entran en ningún modelo; si solo la LSTM las recibiera, no se sabría si gana por leer la secuencia o por tener más información. También usan las mismas particiones y las mismas métricas (PR-AUC, sensibilidad, F1 y calibración). Las particiones siguen un corte cronológico:

- **Corte cronológico:** se entrena con los ordeños más antiguos, se ajustan los hiperparámetros con un periodo intermedio y se prueba con el más reciente (por ejemplo, entrenamiento hasta junio de 2025, validación de julio a septiembre y prueba de octubre de 2025 a enero de 2026). Así la prueba

imita el uso real: predecir ordeños que todavía no ocurren, con un hato que creció de 34 a 182 vacas activas por mes.

- **Test con vacas no vistas:** Después de probar con el dataset de pruebas completo, se prueba con el conjunto de vacas que no se encuentran en el train para ver cómo generaliza con vacas que no conoce.
- **Por qué no al azar:** las variables se construyen con los ordeños anteriores de cada vaca, y los ordeños seguidos casi no cambian. Con un corte al azar, cada ordeño de prueba tendría uno casi idéntico en entrenamiento, y el modelo acertaría por reconocerlo y no por haber aprendido un patrón. Esa fuga favorece más a los modelos que memorizan mejor, como XGBoost, y puede crear una ventaja que no existe (Christodoulou et al., 2019).
- **Modelo final:** los cortes sirven para elegir el modelo y sus hiperparámetros; el modelo elegido se reentrena con todos los datos, incluidos los más recientes.

Ajustes a la preparación de los datos requeridos por los modelos

Se especifican las transformaciones y la limpieza que deben aplicarse a los datos antes de entrenar, para que se cumplan los supuestos de cada modelo.

1. Pasar la conductividad en 0 a NaN y construir rezagos y ventanas por vaca.
2. Aplicar logaritmo, quitar t_sesion del conjunto de la regresión logística y generar un conjunto imputado y estandarizado y otro con NaN.
3. Igualar en la tabla de selección de datos las variables por sesión de los tres modelos: la LSTM recibe en cada paso de la secuencia las mismas variables por sesión que la regresión logística y XGBoost reciben de la sesión previa, en lugar de las mediciones crudas por cuarto.
4. Construir las secuencias de la LSTM y la partición cronológica.
5. Conservar successful_milking_event como objetivo invertido ("alguna anomalía") para los tres modelos.

Reporte de selección de datos

Se seleccionan las variables que utilizarían los modelos para su correcto funcionamiento (no se mencionan las columnas eliminadas que ya se trataron en la limpieza de los datos). La tabla está corregida para que los tres modelos reciban la misma información por sesión y para que successful_milking_event se use como objetivo invertido, como se explica en el reporte de selección del modelo.

Abreviaturas: {q} = 4 columnas, una por cuarto (di, dd, ti, td). "Entra en cada paso de la secuencia" (solo LSTM): la variable entra con el valor de cada una de las k sesiones previas, pero no con el de la sesión que se predice; son las mismas variables por sesión que la regresión logística y XGBoost reciben de la sesión previa. "Se usa antes para calcular / filtrar": no entra al modelo, pero se necesita para calcular otras variables o quitar filas.

Variable	Regresión logística	XGBoost	LSTM
IDENTIFICACIÓN Y CONTROL			
id_vaca	Se quita (se usa antes para calcular). Memorizaría vacas y fallaría con vacas nuevas; solo se usa para calcular el historial.	Se quita (se usa antes para calcular). Haría cortes por vaca y no generalizaría; solo sirve para calcular el historial.	Se quita (se usa antes para calcular). No entra como dato; agrupa las sesiones de cada vaca en su secuencia.
inicio	Se quita (se usa antes para calcular). La fecha cruda no sirve en el futuro; de ella se calculan mes, hora y días en leche.	Se quita (se usa antes para calcular). No puede predecir fechas que no vio; de ella salen las variables de calendario.	Se quita (se usa antes para calcular). Solo ordena la secuencia; de ella salen las variables de calendario.
bloque_historial	Se quita (se usa antes para calcular). Su número no significa nada; solo sirve para calcular dias_en_leche.	Se quita (se usa antes para calcular). Mismo motivo; solo sirve para calcular dias_en_leche.	Se quita (se usa antes para calcular). Marca dónde se corta cada secuencia tras una ausencia larga.
fuente_csv	Se quita. Indica el formato del archivo, no algo de la vaca; se confunde con el periodo.	Se quita. Aprendería el formato del archivo, no a la vaca.	Se quita. Mismo motivo.
accion_rechazada, accion_echada_sin_ordenar	Se quitan (se usan antes para filtrar). Sirven para eliminar esas filas: no son ordeños y no tienen etiqueta.	Se quitan (se usan antes para filtrar). Mismo motivo.	Se quitan (se usan antes para filtrar). Mismo motivo.
CONTEXTO AL ENTRAR AL ROBOT			

intervalo_horas	Se queda. Se conoce antes del ordeño; un regreso antes de 4 h se asocia con eventos. Se escala.	Se queda. Se conoce antes del ordeño; se usa sin transformar.	Se queda. Se conoce antes del ordeño; se escala.
intervalo_horas_sin_dato	Se queda. Avisa que el intervalo fue rellenado y no es real.	Se queda. Mismo motivo.	Se queda. Mismo motivo.
regreso_tras_periodo_seco	Se queda. Primera visita tras más de 48 h fuera: riesgo más alto.	Se queda. Mismo motivo.	Se queda. Mismo motivo.
estado_numero_de_ordeno	Se queda. Ordeño del día; hay que confirmar que se asigna al entrar.	Se queda. Mismo motivo.	Se queda. Mismo motivo.
maquina_7063e4b1, maquina_86696b37	Se quedan. El robot se conoce al entrar y controla diferencias entre equipos.	Se quedan. Mismo motivo.	Se quedan. Mismo motivo.
CLIMA			
t_sesion	Se quita. Correlación de 0.99 con thi_sesion; con las dos, los coeficientes se vuelven inestables y los 3 factores pierden sentido.	Se queda. Si no aporta, los árboles casi no la usan.	Se queda. Contexto de la sesión a predecir; se escala.
thi_sesion	Se queda. Resume temperatura y humedad; al quedar sola, su coeficiente es estable.	Se queda. La correlación con la temperatura no afecta a los árboles.	Se queda. Contexto de la sesión; se escala.
horas_thi_alto_24h	Se queda. Estrés por calor acumulado; solo usa el pasado.	Se queda. Mismo motivo.	Se queda. Mismo motivo.
SEÑALES DE LA MÁQUINA			
sangre_tasa_maquina_30d	Se queda. Tasa de sangre del robot en los 30 días previos; detecta sensores con lecturas anómalas.	Se queda. Mismo motivo.	Se queda. Una secuencia de una sola vaca no ve el estado del robot.
sangre_pico_maquina	Se queda. Le da a un modelo lineal el umbral ya calculado.	Se quita. Es un corte de la tasa anterior, que el árbol hace solo.	Se queda. Le da a la red el umbral ya calculado.
HISTORIAL DE LA VACA (DERIVADAS)			

fme_connection, fme_milk_production, fme_incomplete	Se quedan. Falla mecánica en la sesión anterior: el modelo no tiene memoria y la necesita como columna.	Se quedan. Mismo motivo: tampoco tiene memoria.	Entran en cada paso de la secuencia, con el valor de cada sesión, igual que en RL y XGBoost.
kicks_ratio_7d	Se queda. Patadas por sesión en 7 días; resume el historial en un número.	Se queda. Mismo motivo.	Se quita. La red ve esas sesiones en la secuencia.
blood_diff_{q}	Se quedan 3 de 4. Las 4 suman cero; con las 4 juntas el modelo lineal no puede separar sus efectos.	Se quedan las 4. Esa redundancia no afecta a los árboles.	Entran las 4 en cada paso de la secuencia; es la misma información de sangre que reciben RL y XGBoost.
box_time_to_yield_ratio	Se queda en logaritmo. Tiene valores muy extremos que desbalancean un modelo lineal.	Se queda sin transformar. Los árboles no se afectan por los extremos.	Entra en cada paso de la secuencia, en logaritmo y escalada; resume duración y producción, igual que en RL y XGBoost.
flies_proxy	Se queda. Combina tarde × temperatura × patadas, algo que un modelo lineal no construye solo.	Se queda. Ayuda, aunque los árboles podrían combinarlo solos.	Se quita. La red combina esas variables por sí sola.
CONCENTRADO			
conc_sesion_previa, tope_sesion_previa, conc_d1, conc_media_7d	Se quitan. Solo hay datos desde 2025: train casi vacío y test completo.	Se quitan. Mismo motivo.	Se quitan. Mismo motivo.
MEDICIONES DEL ORDEÑO			
main_produccion_kg	Se quita. Se mide al terminar; 0 kg delata el evento mecánico.	Se quita. Mismo motivo.	Se quita en la sesión a predecir; en las anteriores entra como produccion, igual que produccion_previa en RL y XGBoost.
producciones_kg_{q}	Se quitan. Un cuarto en 0 kg define el evento mecánico.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.

media_de_los_flujos_kg_min_{q}	Se quitan. Se miden durante el ordeño.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
flujos_maximos_kg_min_{q}	Se quitan. Se miden durante el ordeño.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
conductividad_ms_cm_{q}	Se quitan. Se miden durante el ordeño; en su lugar entra conductividad_max_previa.	Se quitan. Mismo motivo; entra conductividad_max_previa.	Se quitan. En cada paso entra conductividad_max, igual que conductividad_max_previa en RL y XGBoost.
contadores_monitorizacion_vaca_{ubre,q}	Se quitan. El robot los genera durante la sesión.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
duracion_seg	Se quita. Se conoce al terminar; los eventos alargan el ordeño unos 2 min.	Se quita. Mismo motivo.	Se quita. La duración entra en cada paso dentro de box_time_to_yield_ratio, igual que en RL y XGBoost.
estado_mdi	Se quita. Define el evento de salud (MDI ≥ 1.4); en su lugar entra mdi_previo.	Se quita. Mismo motivo; entra mdi_previo.	Se quita en la sesión a predecir; en las anteriores entra como mdi, igual que mdi_previo en RL y XGBoost.
estado_amd_ubre	Se quita. Define el evento de salud.	Se quita. Mismo motivo.	Se quita. En las sesiones anteriores ya entra como parte de health_anomaly_event.
sangre_ppm_{q}	Se quitan. Definen el evento de salud (sangre > 0).	Se quitan. Mismo motivo.	Se quitan. La sangre entra en cada paso como blood_diff_{q}, igual que en RL y XGBoost.

amd_pezon_{q}	Se quitan. Definen el evento de salud.	Se quitan. Mismo motivo.	Se quitan. En las sesiones anteriores ya entran como parte de health_anomaly_event.
patada_{q}	Se quitan. Definen el evento de patada.	Se quitan. Mismo motivo.	Se quitan. En cada paso entra behavior_interruption_event, igual que su {evento}_previo en RL y XGBoost.
incompleto_{q}	Se quitan. Definen el evento mecánico.	Se quitan. Mismo motivo.	Se quitan. En cada paso entran mechanical_connection_failure_event y fme_incomplete, igual que en RL y XGBoost.
pezones_no_encontrados_{q}	Se quitan. Definen el evento mecánico.	Se quitan. Mismo motivo.	Se quitan. En cada paso entran mechanical_connection_failure_event y fme_connection, igual que en RL y XGBoost.
cuarto_inactivo_{q}	Se quitan. Salen de la producción de la sesión; en su lugar entra cuarto_inactivo_previo.	Se quitan. Mismo motivo; entra cuarto_inactivo_previo.	Se quitan. En cada paso entra cuarto_inactivo, igual que cuarto_inactivo_previo en RL y XGBoost.
BANDERAS DE CALIDAD Y CONSECUENCIAS			
conductividad_estimada_{q}, conductividad_ms_cm_sin_dato	Se quitan. Dependen de la conductividad de la sesión, que no se usa.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
mdi_faltante, estado_mdi_sin_dato	Se queda como bandera de que mdi_previo fue imputado.	Se queda. Mismo motivo.	Se queda en cada paso como bandera de que el mdi de esa sesión fue imputado.
contadores_faltante	Se quita. Depende de los contadores de la sesión, que no se usan.	Se quita. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.

ordeno_cero_kg, suma_cuartos_distinta	Se quitan. Se calculan con la producción del ordeño.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
sangre_saturada	Se quita. Se calcula con la sangre del ordeño.	Se quita. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
destino_divert, destino_drenaje, destino_sin_ordeno	Se quitan. Son consecuencia del evento: la leche se desvía porque hubo sangre.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
desvio_sangre_por_pezon_por_encima_del_umbral, desvio_separada_manualmente	Se quitan. Son la respuesta, no la causa.	Se quitan. Mismo motivo.	Se quitan. Para comparar en igualdad de información, la red recibe en cada paso los mismos resúmenes por sesión que RL y XGBoost.
ETIQUETAS			
mechanical_connection_failure_event	Objetivo. Un clasificador binario para este evento.	Objetivo. Un clasificador binario para este evento.	Objetivo (una salida sigmoide). En cada paso de la secuencia también entra como historial.
health_anomaly_event	Objetivo. Un clasificador aparte, porque los eventos pueden ocurrir juntos (8.7 %).	Objetivo. Mismo motivo.	Objetivo (una salida sigmoide). En cada paso de la secuencia también entra como historial.
behavior_interruption_event	Objetivo. Un clasificador aparte.	Objetivo. Un clasificador aparte.	Objetivo (una salida sigmoide). En cada paso de la secuencia también entra como historial.

successful_milking_event	Objetivo invertido ("alguna anomalía"). Da directamente la probabilidad de que el ordeño no sea exitoso que pide el BU; sumar las de los otros tres eventos contaría dos veces los ordeños con varios eventos. Nunca entra como variable de entrada.	Objetivo invertido ("alguna anomalía"). Mismo motivo; sus 3 factores salen de TreeSHAP.	Objetivo invertido ("alguna anomalía"). Es una salida sigmoide más de la red.
NUEVAS: ESTACIONALIDAD Y TENDENCIA			
dias_en_leche	Se queda en 7 rangos con dummies. El riesgo tiene forma de U y una recta no la representa.	Se queda como número. Los árboles encuentran la U solos.	Se queda escalado. La red aprende la forma de la curva.
dias_en_hato	Se queda en 5 rangos con dummies. El riesgo es alto al llegar y baja con la adaptación, no en línea recta.	Se queda como número. Los árboles cortan los rangos solos.	Se queda escalado. Mismo motivo.
mes	Se queda en dummies o sen/cos. El número 1–12 haría que diciembre y enero queden lejos.	Se queda como número (1–12). Los árboles lo cortan en rangos.	Se queda en sen/cos. Así diciembre y enero quedan juntos.
hora	Se queda en turnos de 4 h o sen/cos. Así las 23 h y las 0 h quedan cerca.	Se queda como número. Los árboles lo cortan en rangos.	Se queda en sen/cos. Mismo motivo que en RL.
dia_semana	Se queda solo es_domingo. Es el único día distinto (mecánico 15.8 % vs ~14 %).	Se queda como número. El árbol separa el domingo solo.	Se queda en sen/cos. Mismo motivo que el mes.
{evento}_vaca_30d (3 columnas)	Se quedan. Tendencia de la vaca y la variable más fuerte (r = 0.47 mecánico, 0.44 patada).	Se quedan. Mismo motivo.	Se quitan. La red ve esas sesiones en la secuencia.
{evento}_hato_7d (3 columnas)	Se quedan. Nivel de eventos del hato: capta desgaste de robots.	Se quedan. Mismo motivo.	Se quedan. La secuencia de una sola vaca no ve al resto del hato.
vacas_activas_7d	Se queda. El hato creció de 45 a 193 vacas activas en 7 días con 3 robots: mide la carga.	Se queda. Mismo motivo; en la prueba cronológica se revisa si toma valores fuera del rango de entrenamiento.	Se queda. Mismo motivo.

{evento}_previo (3 columnas)	Se quedan. Un evento previo multiplica entre 3 y 4.5 la probabilidad de repetirse.	Se quedan. Mismo motivo.	Entran como los eventos de cada paso de la secuencia.
mdi_previo, conductividad_max_previa, produccion_previa, cuarto_inactivo_previo	Se quedan. Dan al modelo el historial de salud que no puede ver solo.	Se quedan. Mismo motivo.	Entran en cada paso de la secuencia como mdi, conductividad_max, produccion y cuarto_inactivo de esa sesión.
anio, trimestre, índice de tiempo	Se quitan. 2026 no aparece en train, y la recta se prolongaría sin control.	Se quitan. No puede predecir fechas posteriores al entrenamiento.	Se quitan. Mismo motivo; las tasas móviles cubren la tendencia.

Glosario de terminología

Término	Definición
Dropout	Técnica de regularización para redes neuronales que apaga al azar una parte de las neuronas durante el entrenamiento, para evitar que la red dependa de unas pocas y sobreajuste.
SHAP (SHapley Additive exPlanations)	Método basado en teoría de juegos que reparte una predicción entre las variables, indicando cuánto aportó cada una. Permite obtener los factores que más influyeron en cada alerta.
Árbol de decisión	Modelo que predice mediante una serie de reglas "si… entonces" que dividen los datos según los valores de las variables (por ejemplo, intervalo menor a 4 h).
Calibración	Grado en que las probabilidades que da un modelo coinciden con las frecuencias reales: si predice 30 % para un grupo de sesiones, cerca del 30 % de ellas debería presentar el evento.
Coeficiente (peso)	Valor numérico que el modelo asigna a cada variable para indicar cuánto y en qué dirección influye en la predicción.
Early stopping	Técnica que detiene el entrenamiento cuando el error en los datos de validación deja de mejorar, para evitar el sobreajuste.
Época	Una pasada completa del algoritmo de entrenamiento por todos los datos. Las redes neuronales suelen entrenarse durante varias épocas.
Gradient boosting	Técnica que combina árboles de decisión entrenados en secuencia, donde cada árbol nuevo corrige los errores que dejaron los anteriores.

GRU (Gated Recurrent Unit)	Tipo de red neuronal recurrente que usa compuertas para decidir qué información del historial conservar y cuál olvidar. Es una versión más simple de la LSTM.
Hiperparámetro	Configuración del modelo que se define antes de entrenarlo y no se aprende de los datos, como la profundidad de los árboles o la tasa de aprendizaje.
Interacción	Efecto que aparece cuando dos variables juntas influyen de forma distinta a como lo harían por separado; por ejemplo, un intervalo corto combinado con un evento previo.
LSTM (Long Short-Term Memory)	Tipo de red neuronal recurrente diseñada para recordar información de muchas sesiones atrás mediante compuertas que controlan su memoria interna.
Mastitis	Inflamación de la glándula mamaria de la vaca, generalmente por infección, que altera la leche y puede reflejarse en la conductividad eléctrica.
Multitarea	Enfoque en el que un solo modelo aprende a predecir varios resultados a la vez (por ejemplo, varios eventos de ordeño) y comparte lo aprendido entre ellos.
Neurona de salida	Unidad de la última capa de una red neuronal que entrega el resultado final; en este proyecto, una por evento, cada una con su probabilidad.
No linealidad	Relación en la que el efecto de una variable no es proporcional a su valor; por ejemplo, un riesgo que solo aumenta cuando el intervalo baja de cierto número de horas.
Normalización (escalado)	Transformación de las variables para que tengan rangos comparables, de modo que el modelo no favorezca a unas solo por estar en unidades más grandes.
Odds ratio (razón de momios)	Medida de cuánto se multiplican las posibilidades de que ocurra un evento cuando una variable aumenta en una unidad o pasa de ausente a presente.
Random Forest	Modelo que entrena muchos árboles de decisión de forma independiente, cada uno con una muestra distinta de datos y variables, y promedia sus predicciones.
Red neuronal densa	Red neuronal en la que cada neurona de una capa está conectada con todas las neuronas de la capa siguiente.
Red neuronal recurrente	Red neuronal que procesa datos en secuencia y conserva una memoria de los elementos anteriores, adecuada para series de tiempo como los ordeños de una vaca.
Regresión logística	Modelo que combina las variables en una suma ponderada y la transforma con una función sigmoide en una probabilidad entre 0 y 1 de que ocurra un evento.

Regularización	Técnica que penaliza los pesos grandes durante el entrenamiento para que el modelo sea más simple, estable y menos propenso al sobreajuste.
Relleno (padding)	Valores que se agregan a las secuencias más cortas para que todas tengan la misma longitud y puedan procesarse juntas en una red neuronal.
Rezago (lag)	Variable que toma el valor de una sesión anterior; por ejemplo, si hubo patada en el ordeño previo.
Serie de tiempo multivariada	Secuencia de observaciones ordenadas en el tiempo donde cada observación tiene varias variables, como cada ordeño con su duración, producción y conductividad.
Sigmoide	Función que transforma cualquier número en un valor entre 0 y 1, por lo que se usa para expresar probabilidades.
Sobreajuste (overfitting)	Problema que ocurre cuando un modelo se ajusta demasiado a los datos de entrenamiento y no generaliza bien a datos nuevos.
Tasa de aprendizaje	Hiperparámetro que controla qué tanto se ajustan los pesos del modelo en cada paso del entrenamiento.
THI (Índice de Temperatura y Humedad)	Índice que combina temperatura y humedad relativa para estimar el estrés por calor en el ganado.
Validación cronológica	Forma de evaluar el modelo en la que se entrena con ordeños anteriores y se prueba con ordeños posteriores, para que el resultado refleje su desempeño en fechas que no vio.
Valor atípico	Observación que se aleja mucho del resto de los datos. En este proyecto no se elimina, porque puede ser justamente la anomalía buscada.
Variable de cola larga	Variable cuya distribución tiene la mayoría de valores agrupados y unos pocos valores muy extremos, como la sangre en leche (0 en la mayoría de ordeños, hasta 8,000 ppm).
Ventana	Número de sesiones anteriores que se usan para calcular una variable o que recibe el modelo; por ejemplo, los últimos 10 a 20 ordeños de la vaca.
XGBoost	Implementación eficiente y regularizada de gradient boosting, ampliamente usada con datos tabulares.

Fuentes bibliográficas.

Neupane, R., Ceja, G., Daigle, C., Tedeschi, L. O., Khanal, P., Valeris-Chacin, R., Xu, Z., & Paudyal, S. (2026). Characterization of failed milking events in a voluntary milking system. *Journal of Dairy Science*, *109*(8), 8424–8434. https://doi.org/10.3168/jds.2025-28232

Perttu, R. K., Heins, B. J., Phillips, H. N., Endres, M. I., Moon, R. D., & Sorge, U. S. (2020). Short communication: Effects of mesh leggings on fly pressure and fly avoidance behaviors of pastured dairy cows. *Journal of Dairy Science*, *103*(1), 846–851. https://doi.org/10.3168/jds.2019-17267

Hernández-Gotelli, C., & Pinedo, P. J. (2026). Association between health status and the temporal dynamics of milking behavior and performance in early-lactation cows in an automatic milking system. *Frontiers in Animal Science*, *7*, Artículo 1887014. https://doi.org/10.3389/fanim.2026.1887014

Langlois, D. (2023). Rest feed calculation. West Coast Robotics. https://www.westcoastrobotics.ca/post/rest-feed-calculation

Talukder, S., Qiu, D., Thomson, P. C., Cheng, L., & Cullen, B. R. (2024). Impact of heat stress on dairy cow rumination, milking frequency, milk yield and quality in a pasture-based automatic milking system. *Animal Production Science*, *64*, Artículo AN22334. https://doi.org/10.1071/AN22334

Kashongwe, O., Kabelitz, T., Ammon, C., Minogue, L., Doherr, M., Silva Boloña, P., Amon, T., & Amon, B. (2024). Influence of preprocessing methods of automated milking systems data on prediction of mastitis with machine learning models. *AgriEngineering*, *6*(3), 3427–3442. https://doi.org/10.3390/agriengineering6030195

Solano, L., Halbach, C., Bennett, T. B., & Cook, N. B. (2022). Milking time behavior of dairy cows in a free-flow automated milking system. *JDS Communications*, *3*(6), 426–430. https://doi.org/10.3168/jdsc.2022-0243

Schwanke, A. J., Dancy, K. M., Didry, T., Penner, G. B., & DeVries, T. J. (2019). Effects of concentrate location on the behavior and production of dairy cows milked in a free-traffic automated milking system. *Journal of Dairy Science*, 102, 9827–9841. https://doi.org/10.3168/jds.2019-16756

Fan, X., Watters, R. D., Nydam, D. V., Virkler, P. D., Wieland, M., & Reed, K. F. (2023). Multivariable time series classification for clinical mastitis detection and prediction in automated milking systems. *Journal of Dairy Science*, *106*(5), 3448–3464. https://doi.org/10.3168/jds.2022-22355

Phillips, H. N., Heins, B. J., & Moon, R. D. (2023). The defensive behaviors and milk production of pastured dairy cattle in response to stable flies, horn flies, and face flies. *Animals*, *13*(24), Artículo 3847. https://doi.org/10.3390/ani13243847

Morales-Piñeyrúa, J. T., Damián, J. P., Banchero, G., & Sant'Anna, A. C. (2022). The effects of heat stress on milk production and the grazing behavior of dairy Holstein cows milked by an automatic milking system. *Journal of Animal Science*, *100*(9), Artículo skac225. https://doi.org/10.1093/jas/skac225

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., & Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. Journal of Clinical Epidemiology, 110, 12–22. https://doi.org/10.1016/j.jclinepi.2019.02.004

Dharejo, M. N., Minogue, L., Kabelitz, T., Amon, T., Kashongwe, O., & Doherr, M. G. (2025). Time series data analysis to predict the status of mastitis in dairy cows by applying machine learning models to automated milking systems data. Preventive Veterinary Medicine, 242, 106575. https://doi.org/10.1016/j.prevetmed.2025.106575

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? Advances in Neural Information Processing Systems, 35. https://doi.org/10.48550/arXiv.2207.08815

Zhu, J., Vasseur, E., & Wade, K. M. (2026). A multi-stage analysis of automatic milking system data: Integrating descriptive, predictive, and prescriptive analytics for dairy health management. Biosystems Engineering, 265, 104433. https://doi.org/10.1016/j.biosystemseng.2026.104433