Reporte: Entendimiento de los datos
Por PINU

Resumen **1**
1. Adaptaciones de la metodología CRISP-DM **2**
2. Recolección de datos iniciales **2**
2.1 Ubicación y obtención 2
2.2 Problemas encontrados y soluciones 3
3. Descripción de los datos **3**
3.1 Fuentes 3
3.2 Formato y tipos de datos 4
3.3 Descripción de columnas del dataset 5
3.4 Características del dataset 6
3.5 Clima 7
4. Satisfacción de los requerimientos **7**
5. Exploración de los datos **9**
5.1 Visualizar y consultar los datos 10
5.2 Patrones y distribuciones 11
5.3 Problema de cola 14
5.4 Clima integrado 16
5.5 Hipótesis iniciales 18
6. Calidad de los datos **18**
6.1 Análisis de la calidad 18
6.2 Datos atípicos 20
6.3 Métodos de limpieza recomendados 21
7. Implicaciones para el modelado **22**
Anexo: calidad por columna de los historiales CSV 22
8. Glosario **24**

Resumen

- **Los datos sirven para el objetivo, con tratamientos claros.** Hay 280,697 ordeños de 207 vacas en tres robots (13/07/2022 a 28/01/2026), con identificador de vaca en el 100 % de las filas y clima de NASA POWER para el 100 % de las sesiones. Necesitan limpieza (dos formatos de fecha, sesiones repetidas entre fuentes, ceros de conductividad que son faltantes y columnas vacías), pero nada impide modelar.
- **Los eventos son del 12 al 16 % de los ordeños.** Un modelo que siempre responda "sin evento" ya tiene 84 a 88 % de accuracy por evento, así que el criterio de 80 % no basta por sí solo.
- **El clima casi no se relaciona con el ordeño** ($|r| \leq 0.03$ con los eventos). Pesan más el historial de la vaca (un evento previo multiplica de 3.3 a 4.5 veces la probabilidad del siguiente), el intervalo desde el ordeño anterior y el estado de los cuartos.

- **Hay señales de problema de cola, pero no se mide directamente:** la ocupación de las máquinas pasó de 13 % a 71 % y los relevos pegados de 21 % a 80 % entre 2022 y 2026, con las mismas tres máquinas.
- **Pendientes con el socio formador:** definir las clases de evento, las pausas de las 4, 12 y 20 h, el sensor de conductividad del cuarto trasero derecho.

1. Adaptaciones de la metodología CRISP-DM

Se agregó una sección de glosario, con el fin de que cada interesado al proyecto pueda comprender todos los temas que se tratan dentro del mismo.

2. Recolección de datos iniciales

Esta sección documenta la ubicación y el origen de los datos, cómo se obtuvieron, las dificultades al recolectarlos y cómo se resolvieron. Los datos adicionales también se incluyen, aunque pueden cambiar en iteraciones posteriores de CRISP-DM.

2.1 Ubicación y obtención

Los datos provienen del Campo AGRO Experimental del Tecnológico de Monterrey (CAETEC), en el kilómetro 188 de la carretera México-Querétaro. El CAETEC tiene un sistema de ordeño automatizado DeLaval que permite el ordeño voluntario e identifica a cada vaca para registrar cada sesión. El profesor Benjamín Valdés Aguirre entregó los datos por Canvas a inicios de septiembre de 2026, en un Google Drive con acceso limitado a cuentas del Tecnológico de Monterrey.

Tras una revisión inicial, los datos se agruparon en seis conjuntos principales:

Conjunto de datos	Medio de obtención	Formato	Organización
Registros de ordeño de vacas	Sistema DeLaval	.csv	Un archivo por vaca
inventario_total_180725	Sistema DeLaval	.csv	Archivo consolidado
patadas_180725	Sistema DeLaval	.csv	Archivo consolidado
reporte_180725	Sistema DeLaval	.csv	Archivo consolidado
Producciones de leche por sesión	Sistema DeLaval	.xlsx	Un archivo por vaca
Concentrado consumido	Sistema DeLaval	.xlsx	Un archivo por vaca

Los integrantes del equipo descargaron los archivos del Drive. Las copias se modificaron de manera pertinente para las siguientes etapas de la metodología, pero el Drive original se mantuvo como fuente de verdad.

2.2 Problemas encontrados y soluciones

Problema	Solución
El Drive solo era accesible con cuentas institucionales del Tec.	Se usaron las cuentas institucionales del equipo y se guardó una copia local sin modificar.
Archivos repartidos en varias carpetas sin estándar, en .csv y .xlsx, unos por vaca y otros consolidados (como el de patadas), con nomenclaturas distintas.	Se revisaron carpetas y archivos y se agruparon en los seis conjuntos por tipo de información, formato y organización.
Origen de los conjuntos no documentado.	Se confirmó con el socio posteriormente que los datos de ordeño vienen del sistema DeLaval, así como los consolidados a mano, como el “inventario total” y “concentrado consumido”.
Faltaban datos de clima de la zona del CAETEC, que el equipo decidió necesarios después de la recolección inicial.	Se integró la serie climática horaria de NASA POWER (sección 3).

3. Descripción de los datos

Se recibieron 442 archivos en dos carpetas: *TEC-UAQ-UNAM* (Excel de producción y consumo) y *DATOS vacas en establo marzo_junio_2025* (CSV y un DOCX). Los datos son tabulares con un archivo por vaca y por tipo de registro; el identificador de la vaca está en el nombre del archivo y no en una columna. Como fuente externa se usa la serie climática horaria de NASA POWER (API v2.10.2).

3.1 Fuentes

Fuente	Archivos y formato	Estructura	Contenido principal
Producción de leche por sesión	201 XLSX	2 filas de encabezado, 42 columnas	Hora, sesión, duración, kg, intervalo, flujo, sangre, conductividad y producción por cuarto, VMS, destino de la leche, banderas de estado de ordeño

Fuente	Archivos y formato	Estructura	Contenido principal
Historiales de ordeño	34 CSV	2 filas de encabezado, 35 columnas	Mismas variables de ordeño, más la columna Acción
Consumo de concentrado	203 XLSX	1 fila de encabezado, 4 columnas	Alimento, hora, consumido, consumido en materia seca
Resúmenes del 18/07/2025	3 CSV	Patadas (coma, 43 col., 37 reg.); inventario "secas" (;, 41 col., 33 reg.); reporte activo (;, 22 col., 34 reg.)	Estado reproductivo, días en leche, patadas, grupo
Clima (NASA POWER)	1 CSV	1 fila de encabezado, 14 columnas	Hora local y 13 variables: temperatura, humedad, punto de rocío, bulbo húmedo, humedad específica, presión, viento (2 y 10 m) y dirección, precipitación, radiación de onda corta y larga, nubosidad

Tras la consolidación, el ordeño queda en Data/dataset_vacas_anonimo.csv (reportes csv de marzo a julio de 2025 e históricos xlsx de 2022 a 2026): 286,217 filas y 44 columnas, donde cada fila es una visita de una vaca a una máquina. El concentrado queda en Data/dataset_concentrado_anonimo.csv (vacas/4.0): 129,532 registros de 202 vacas, del 28/01/2025 al 28/01/2026. Tras una limpieza inicial quedan 280,915 filas: 280,697 ordeños de las tres máquinas (base del análisis), 216 visitas rechazadas o de “echada sin ordeñar” (solo en 2025) y 2 sesiones de un cuarto valor de máquina.

3.2 Formato y tipos de datos

El archivo de ordeño tiene 30 columnas numéricas (float64) y 14 de texto. Pandas asigna un tipo distinto al real en varias:

Columna	Problema	Tratamiento
main_hora_de_inicio	Texto en dos formatos: csv 01/03/2025 05:37 a. m. y xlsx 2025-03-01 05:37:12	datetime (inicio)

Columna	Problema	Tratamiento
main_duracion_mm_ss	mm:ss en el csv y hh:mm:ss en el xlsx	Segundos
main_intervalo_de_ordeno_hh_mm	Los de 24 h o más están guardados como fecha de Excel	Horas
estado_patada, _incompleto, _pezones_no_encontrados, _amd_pezon	Texto con lista de cuartos (DI,TD, Todos); el nulo significa "no ocurrió"	Banderas 0/1 por cuarto
estado_numero_de_ordeno, estado_amd_ubre	float solo por tener nulos	Sin cambio
id_vaca, misc_eo_po	Hashes (identificadores, no cantidades)	Texto

Otras particularidades de formato: etiquetas repetidas en el encabezado (DI, DD, TI y TD aparecen en cinco bloques), dos CSV de resumen separados por punto y coma, el símbolo “?” como nulo, nombres de archivo con codificación dañada y tres libros de consumo con nombre irregular (uno sin ID).

Tipos de variable:

- **Temporales:** fecha y hora de inicio del ordeño.
- **Numéricas continuas:** producción, duración, intervalo entre ordeños, flujo (kg/min), producción, sangre (ppm) y conductividad (mS/cm) por cuarto (DI, DD, TI, TD), MDI, consumo (cantidad y materia seca, sin unidad explícita), las 13 variables climáticas y el THI.
- **Discretas:** número de ordeño del día y banderas de patada, incompleto y pezón no encontrado.
- **Categóricas:** máquina (VMS 1 a 3), destino de la leche (Tanque, Drenaje, Divert 1 a 3), alimento (un único valor: Feed1) y acción (ordeño, rechazada, echada sin ordeñar; solo en los CSV).
- **Identificadores:** id_vaca y, para trazabilidad, archivo y fila de origen.

3.3 Descripción de columnas del dataset

3.4 Características del dataset

- **Instancia:** Una visita de una vaca a la máquina. Tres máquinas con carga parecida (91 a 98 mil ordeños cada una) y una cuarta máquina valor con 2 registros.
- **Vacas:** 207, con mediana de 1,264 sesiones (mínimo 2, máximo 3,569; tres vacas con menos de 30); 144 vacas inician su registro antes del 28/01/2025 y 201 tienen datos de ordeño y de consumo. El hato crece de 34 vacas activas por mes (julio de 2022) a 182 (enero de 2026) con las mismas máquinas.
- **Columnas:** identificación y resumen (main_*), estado y eventos (estado_*), cinco mediciones por cuarto (producción, flujo medio y máximo, sangre, conductividad; sufijos _di, _dd, _ti, _td) y contexto (misc_*: máquina, destino de la leche, razón de la desviación).
- **No existe:** hora de salida (solo inicio y duración), fecha de parto, etiquetas de salud ni hora de llegada a la fila. El destino de la leche es “Tanque” en 94 % de los casos.
- **Tipo de visita y eventos:** el 99.9 % de las visitas son ordeños; el 0.1 % restante son 216 visitas rechazadas o de "echada sin ordeñar", que solo se registran en 2025. Uno de cada tres ordeños (32.6 %) tiene al menos un evento (patada, incompleto, pezón no encontrado o AMD de pezón).

Estadística básica (280,697 ordeños; los estadísticos se calculan sobre los valores válidos):

Variable	% nulos	Media	Desv. est.	Mín	Q1	Mediana	Q3	Máx
Producción por ordeño (kg)	0.0	14.82	5.34	0.00	11.07	14.29	18.10	78.17
Duración (min)	0.0	8.10	2.58	0.38	6.25	7.60	9.40	55.80
Intervalo desde el ordeño anterior (h)	0.2	9.92	3.86	0.01	7.41	9.21	11.64	47.92
Número de ordeño del día	0.0	1.84	0.84	1	1	2	2	6
Flujo medio (kg/min, sin ceros)	0.1	1.19	0.32	0.06	0.96	1.18	1.40	4.62
Conductividad media (mS/cm, sin ceros)	0.1	4.95	0.48	0.40	4.64	4.93	5.23	11.22

Variable	% nulos	Media	Desv. est.	Mín	Q1	Mediana	Q3	Máx
MDI	8.4	1.23	0.42	0.71	1.06	1.10	1.18	15.36
Sangre máxima entre cuartos (ppm)	0.0	52.55	386.39	0	0	0	0	8,000
Producción cuarto DI (kg)	1.9	3.51	1.58	0.00	2.49	3.38	4.42	39.84
Producción cuarto DD (kg)	2.6	3.64	1.58	0.00	2.61	3.50	4.55	38.71
Producción cuarto TI (kg)	1.6	4.12	2.04	0.00	2.88	4.02	5.33	31.42
Producción cuarto TD (kg)	3.9	3.93	2.03	0.00	2.70	3.85	5.12	39.06

La producción, la duración y el intervalo son asimétricos a la derecha: la media supera a la mediana en 3.7, 6.5 y 7.8 %. La sangre es 0 en más del 75 % de los ordeños pero llega a 8,000 ppm. El número de ordeño del día es casi siempre de 1 a 3 (en 45.5 % de los días-vaca hay 2 ordeños y en 36.4 % hay 3). Los mínimos de 0 en la producción por cuarto son cuartos sin leche. Los eventos son variables 0/1: patada 16.1 %, incompleto 11.9 %, pezón no encontrado 11.8 % y AMD de pezón 9.3 % de los ordeños. El consumo de concentrado tiene mediana de 1.09 por evento (unidad original; máximo 4.72) y mediana de 3 eventos al día por vaca.

3.5 Clima

La serie de NASA POWER cubre 31,104 horas (13/07/2022 a 28/01/2026), el mismo periodo que los ordeños, con 13 variables y sin faltantes; la precipitación sí trae datos. Cada valor representa una celda de ½° × ⅝° (≈ 55 × 65 km) en el exterior. La fila etiquetada *t* describe el clima de *t* + 1 h, así que cada sesión de la hora *T* toma la fila de *T* − 1 h; con esa regla el 100 % de las sesiones tiene clima. Se calculó el THI:

$$THI = (1.8T + 32) - (0.55 - 0.0055 \cdot HR)(1.8T - 26)$$

La temperatura tiene una mediana de 16.4 °C (de 0.6 a 35.9 °C). El THI tiene mediana de 60.9 y percentil 90 de 70.8; el 21.8 % de las horas y el 21.2 % de las sesiones ocurren con THI ≥ 68.

4. Satisfacción de los requerimientos

Los datos satisfacen los requerimientos esenciales (identificador, historial y variables ambientales) y permiten avanzar a la preparación de datos.

Requerimiento	Estado	Evidencia
Identificador único de vaca en cada observación	**Cumple**	id_vaca sin nulos (207 vacas), derivado del nombre del archivo; 201 vacas coinciden entre leche y consumo. Pendientes: un libro de consumo sin ID (783 eventos) y 6 vacas que solo están en CSV
Información histórica suficiente para entrenar	**Cumple parcialmente**	Historial de ordeño desde julio de 2022 (3.5 años); el concentrado y los rechazos solo cubren 2025-2026 y hay una sola fuente (CAETEC)
Variables del proceso de ordeño y del ambiente	**Cumple**	Duración, producción, flujo, conductividad, sangre, MDI, alertas por cuarto, destino de la leche; 13 variables de clima e índice THI
Clima preciso con la ubicación del rancho	**Parcial**	Celda de NASA POWER de ≈ 55 × 65 km, de exterior y no del establo, con la hora desfasada una hora (se corrige)
Definir las clases de evento	**Parcial**	Hay cuatro banderas; el incompleto y el pezón no encontrado coinciden en 79 a 80 %; Acción solo está en los CSV; RCS está 100 % vacío; no hay etiqueta clínica ni de lactación
Probabilidad y 3 factores por alerta	**Pendiente (modelado)**	Hay variables candidatas para modelos interpretables: evento previo de la vaca, intervalo, cuartos sin leche
Permiso y protección de los datos	**Cumple / por documentar**	Vacas y máquinas anonimizadas; Data/ y el mapa de equivalencias fuera del repositorio. El permiso es un supuesto del BU y se prepara un documento con las políticas de acceso
Causas del incompleto revisadas por el socio formador	**Pendiente**	Preguntas en la sección 8

Criterios de éxito. Como los eventos son poco frecuentes, un modelo que siempre responda "sin evento" ya acierta en la mayoría de los ordeños sin detectar ninguno. Su accuracy es: 100 % - la frecuencia del evento:

- 83.9 % para patada (100 − 16.1),
- 88.1 % para incompleto (100 − 11.9) y
- 88.2 % para pezón no encontrado (100 − 11.8).

Por eso el criterio de 80 % no basta por sí solo y debe acompañarse de precisión, sensibilidad y F1, con validación por vaca y por tiempo.

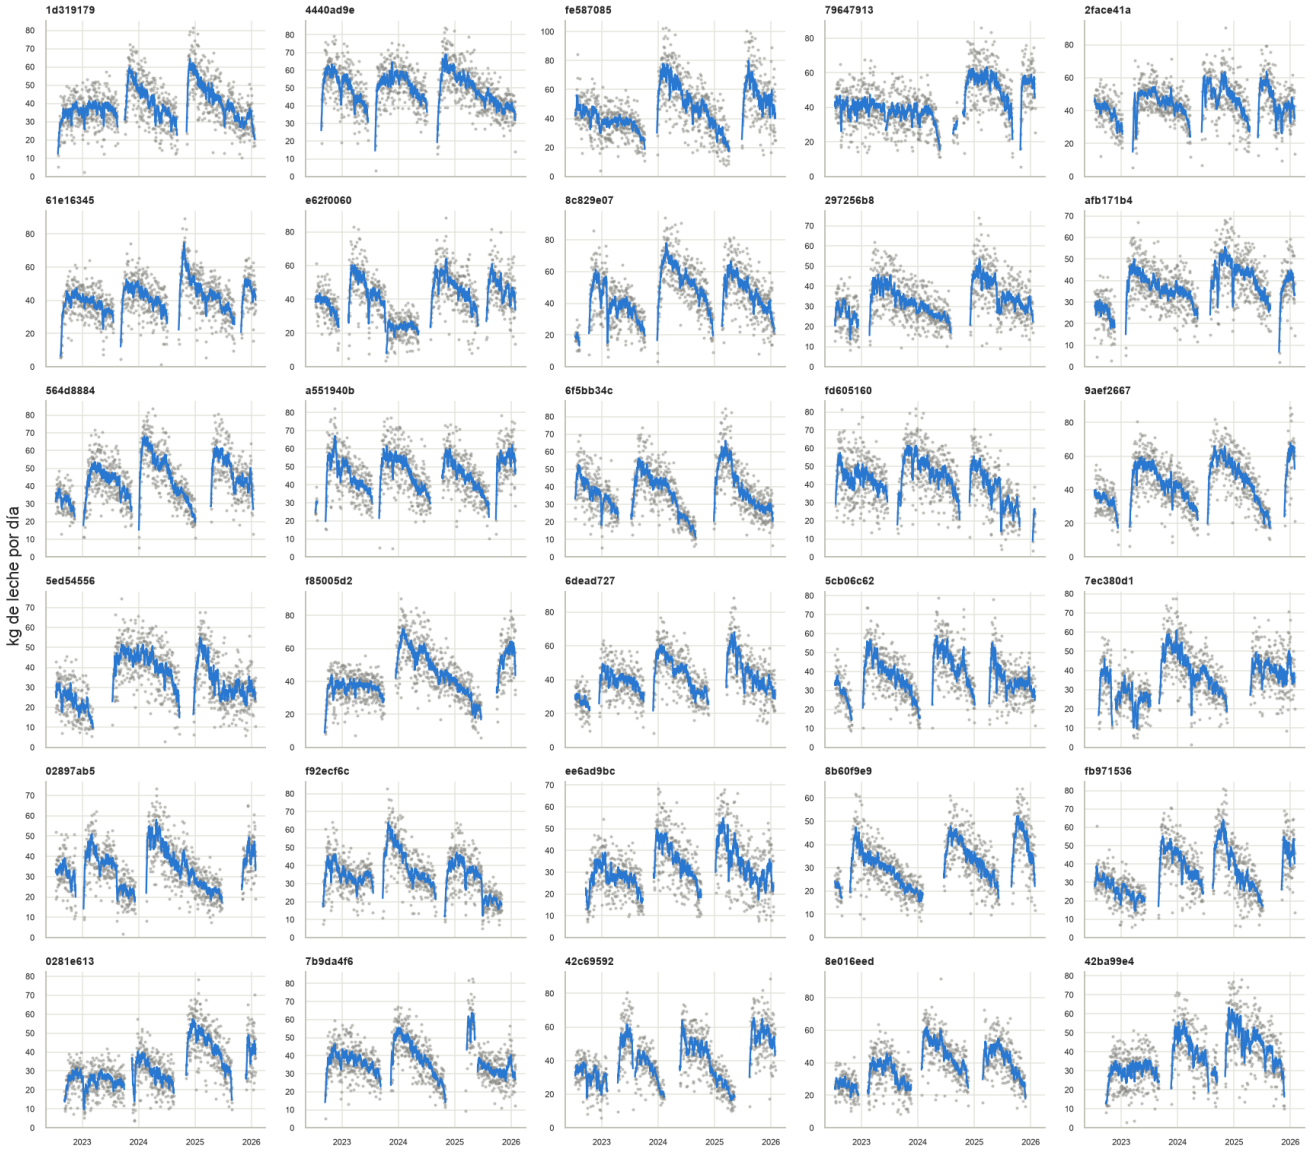
Supuestos y limitaciones frente a los datos:

1. Los datos de ordeño abarcan desde julio de 2022, no solo 2025-2026; solo el concentrado y los rechazos son de 2025-2026.
2. El desbalance de eventos se confirma.
3. Los datos de producción son completos solo en parte: hay periodos secos y 28 % de ceros de conductividad en un cuarto.
4. Se asume una relación entre clima y eventos, pero la evidencia es débil.
5. El clima viene de reanálisis y observación, no de pronóstico; falta decidir qué usar al desplegar.

5. Exploración de los datos

En esta sección se usó el dataset ya anonimizado para poder obtener información de los datos y comprender diferentes patrones y relaciones entre ellos. No se realizó un proceso de limpieza extenso para la exploración. Se revisan la producción y la lactancia, los patrones por hora, mes e intervalo, los cuartos y las máquinas, los eventos (patada, incompleto, pezón no encontrado y AMD de pezón), la señal de cola y la relación con el clima. Los resultados son exploratorios: describen asociaciones y no demuestran causas.

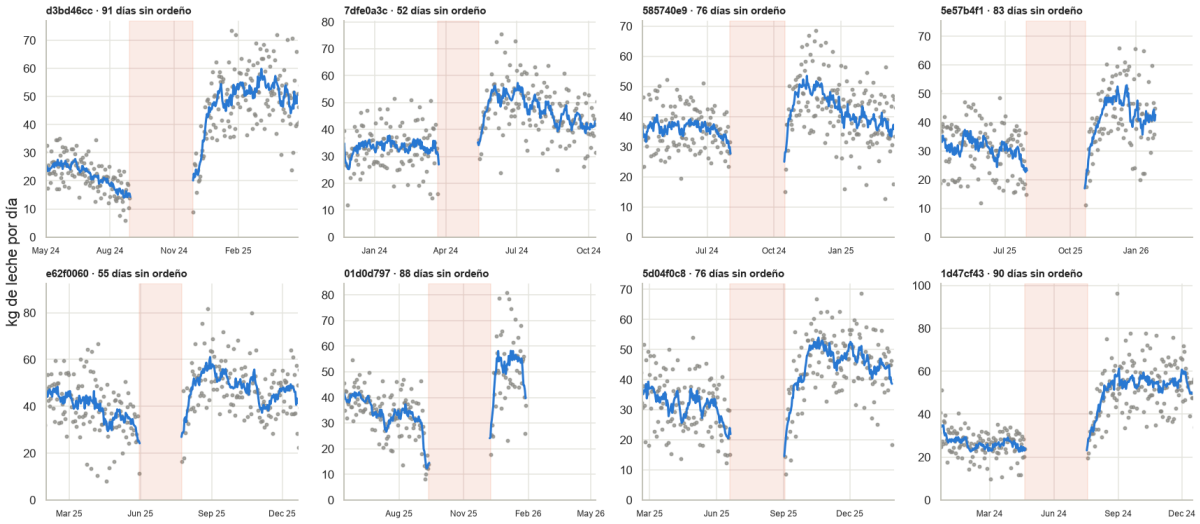
5.1 Visualizar y consultar los datos



Cada punto gris es la producción de un día y la línea azul el promedio de 7 días.

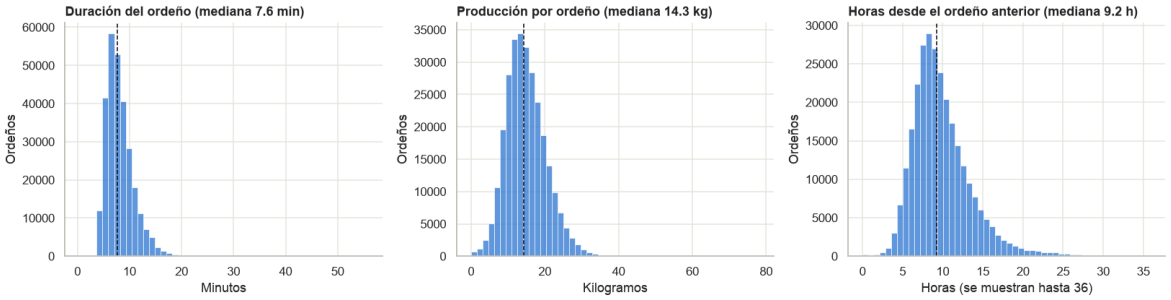
Ausencias de más de 40 días. Hay 237 ausencias de más de 40 días (de 129 vacas), con mediana de 81 días, compatible con un periodo de secado; no deben interpretarse como producción cero. Al volver, las vacas producen unos 24 kg al día, como antes de irse (25 kg), y llegan a un pico de unos 55 kg en una mediana de 45 días. Estas ausencias explican los intervalos de más de 48 h y, como no hay fecha de parto, son la única forma de estimar la etapa de lactancia.

La producción diaria por vaca sigue la curva de lactancia (pico tras el parto y descenso gradual). Es dispersa porque depende de cuántas veces vino la vaca: 17.6 kg con un ordeño, 31.1 con dos y 42.0 con tres.

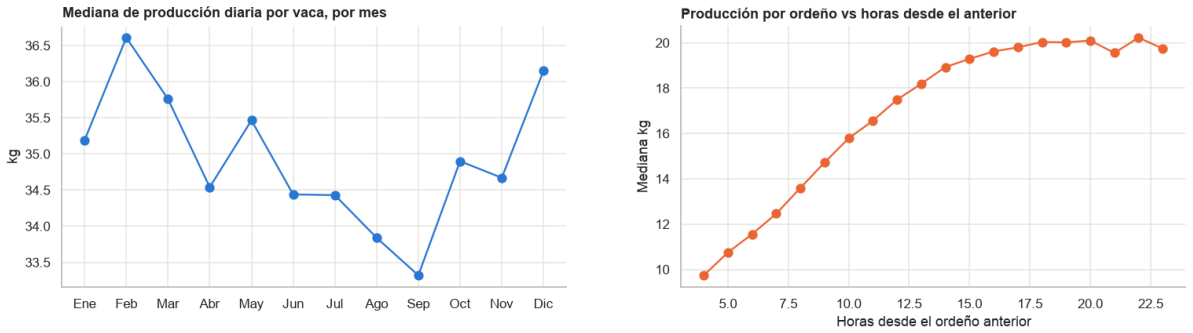


Las zonas naranjas son los días sin ningún ordeño; son ejemplos de ausencias de más de 40 días con historia antes y después.

5.2 Patrones y distribuciones



Distribuciones: producción, duración e intervalo son asimétricas a la derecha, con una cola de valores altos. Conviene usar métodos robustos o transformarlas al modelar.



Producción por mes: la mediana de producción diaria por vaca varía cerca de 10 % entre el mes más bajo (33.3 kg en septiembre) y el más alto (36.6 kg en febrero), pero no se puede separar de la etapa de lactancia, porque no hay fecha de parto.

Producción por intervalo: la producción por ordeño sube casi en línea recta con las horas desde el ordeño anterior (de unos 10 kg con 4 h a unos 19 kg con 15 h) y

luego se estabiliza cerca de 20 kg. Por eso un ordeño con poca leche puede ser normal si el intervalo fue corto.

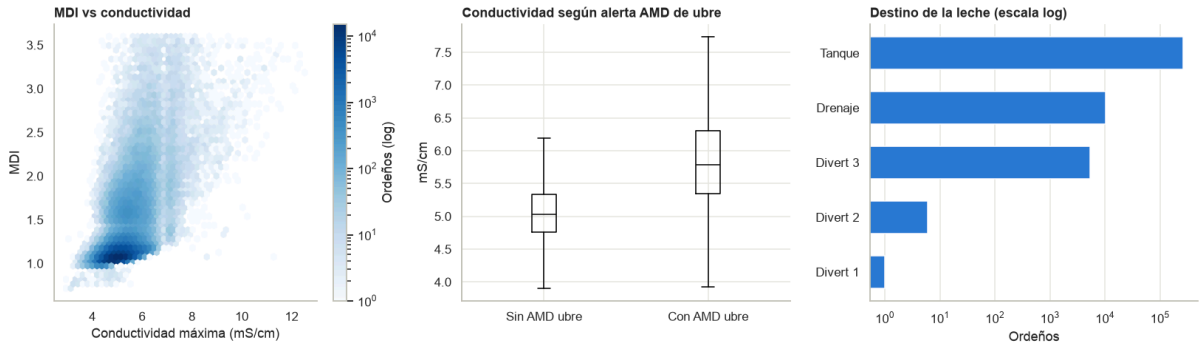


Cuartos y máquinas: los cuartos traseros producen más (4.1 y 4.0 kg contra 3.4 y 3.5 kg) porque se ordeñan más tiempo, con flujo y conductividad casi iguales. También se quedan sin leche más veces (4.6 y 4.7 % contra 1.5 y 1.6 %): en 10.2 % de los ordeños algún cuarto da 0 kg, y los traseros concentran el 75 % de esos casos. La máquina no explica los eventos (V de Cramér ≤ 0.025).

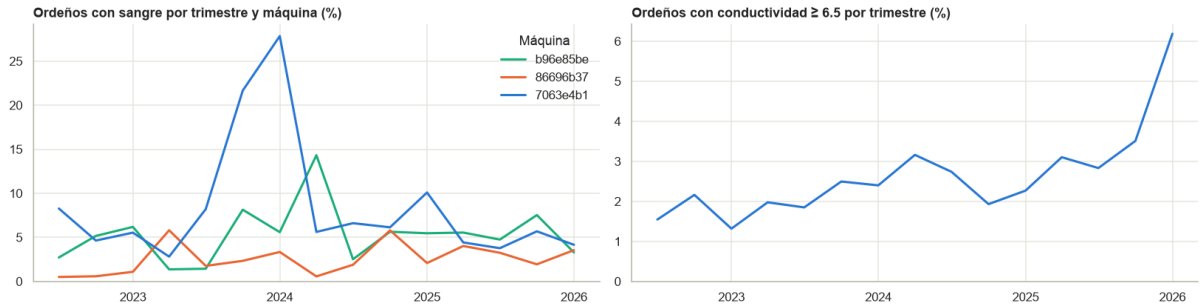
Eventos: se concentran en pocas vacas (el 10 % de ellas acumula 38 % de las patadas) y se repiten. Tras un evento en la sesión anterior, la probabilidad de repetirlo es 39.9% (patada), 30.9% (incompleto) y 37.5% (pezón), contra 11.5, 9.4 y 8.3% sin evento previo. El incompleto se dispara si la vaca regresa antes de 4 h (32.7% contra 10.7 a 12.5%) y las vacas nuevas tienen más eventos en sus primeras semanas.

Eventos en detalle. El incompleto y el pezón no encontrado coinciden en 79 y 80 % y afectan más a los cuartos traseros (5.0 a 5.6 % contra 1.9 a 2.5 % de los delanteros). El AMD de pezón varía entre máquinas (6.1 a 12.5 %). El incompleto subió de 9.4% en 2022 a 12.7% en 2025 y 40 vacas lo tienen en más del 20% de

sus ordeños. Los rechazos y las “echada sin ordeñar” solo se registran en 2025 (2.4 y 0.8 % de las visitas).



Salud de la ubre: suben juntos,aunque la relación es moderada y la mayoría de los ordeños se concentran en valores típicos (entre 4 a 6 mS/cm y MDI entre 1 y 1.5), y los ordeños con alerta AMD de ubre tienen una conductividad mediana más alta que los que no (5.79 contra 5.03 mS/cm). Sin embargo, los dos grupos se traslapan, así que la conductividad sola no basta para detectar el problema. Estos tres indicadores sirven como una señal conjunta de un posible problema de ubre, sin llegar a ser un diagnóstico, porque no hay etiquetas de mastitis. En la parte de destino de la leche (escala logarítmica), podemos ver que la mayoría de la leche llega al tanque, seguida del drenaje; el resto se reparte en los Diverts, siendo Divert 3 el más frecuente.



Sangre y conductividad en detalle. Aparece sangre en 5.5% de los ordeños y en 204 de las 207 vacas, más en los cuartos delanteros (2.6% en DI contra 1.1% en TD); sólo 1.1% de los ordeños pasan de 1,000 ppm. Con más de 1,000 ppm el 78.9% de la leche va a Divert 3 (0.5% sin sangre); con conductividad ≥ 6.5 (2.7% de los ordeños) sube el drenaje (12.7% contra 3.6%). La conductividad alta subió de 1.9% en 2022 a 3.0% en 2025 y se concentra en pocas vacas (12 con más del 10% de sus ordeños). Por máquina, la sangre tiene picos de hasta 27.8% de los ordeños en 7063e4b1 en el primer trimestre de 2024, y las mismas vacas dan 8.4, 2.9 y 6.4 % según la máquina, así que conviene revisar esos sensores con Aurelio.

5.3 Problema de cola

El dataset no registra la llegada de la vaca a la fila ni la espera, solo el inicio y la duración del ordeño, así que la cola se infiere de qué tan pegados quedan los ordeños consecutivos de una misma máquina:

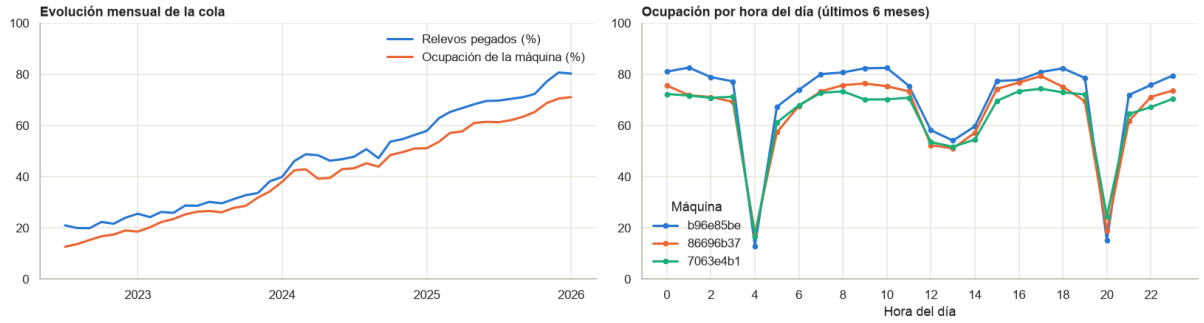
Cómo se mide:

1. **Hueco:** inicio de la vaca siguiente − (inicio + duración) de la vaca anterior en la misma máquina (mínimo 0). Si la siguiente es otra vaca y entra a 1 min o menos del fin de la anterior, el relevo es “pegado” (probablemente había alguien esperando).
2. **Ocupación (ρ):** suma de las duraciones de los ordeños de la máquina entre el tiempo observado.
3. **Espera estimada:** fórmula de la teoría de cola “Pollaczek-Khinchine” (cola M/G/1, con llegadas al azar y una vaca atendida a la vez; ver glosario):

$$W = \frac{\rho \cdot E[S] \cdot (1 + CV^2)}{2(1-\rho)}$$

Donde E[S] es la duración media del ordeño (min) y CV su coeficiente de variación. Por ejemplo, con ρ = 0.73, E[S] = 8.1 min y CV = 0.32 la espera es de unos 12 min.

Indicador	Resultado
Relevos pegados (1 min o menos)	De 18.1 % (2022) a 73.9% (2026)
Ocupación de las máquinas	De 12.6 % a 71.1 %
Carga actual por máquina (últimos 3 meses)	121 a 126 ordeños al día, 67 a 73 % de ocupación, hueco mediano de 0.5 a 0.6 min
Espera estimada (llegadas al azar)	De 8.8 a 12.9 min por vaca
Holgura	Solo las pausas de las 4:00 y las 20:00



Hay caídas cerca de las 4, 12 y 20 h. La ocupación baja a unos 16 % a las 4 h y a unos 20 % a las 20 h; a las 12 h baja solo a cerca de 55 %, por lo que ahí no hay holgura real.

La fórmula supone llegadas aleatorias y una cola independiente por máquina, y crece rápido cuando ρ se acerca a 1. Las vacas no llegan al azar (horarios y pausas), así que la espera es una estimación orientativa y no una medición.

Huecos y rachas de cola

Qué es el hueco: es el tiempo que la máquina estuvo libre entre dos ordeños. No es la espera de la vaca, pero un hueco muy corto indica que la siguiente entró apenas terminó la anterior.

Por qué un relevo pegado aislado no basta: el hueco mediano (percentil 50) es de unos 33 s (percentil 25: 25 s; percentil 75: 79 s), que parece ser el mínimo físico de cambiar de vaca. El 71 % de los relevos de los últimos 3 meses tiene un hueco de 1 min o menos, así que un solo relevo pegado es lo normal. Por eso se habla de episodios.

Episodio de cola: racha de 5 o más ordeños seguidos en la misma máquina, cada uno empezando 1 min o menos después de que terminó el anterior; es decir, la máquina trabajó con casi ninguna pausa. En los últimos 3 meses hubo 1,862 episodios (6.7 por máquina y día). Un episodio típico incluye 8 ordeños y dura 71 min; el 10 % más largo llega a 15 ordeños y 128 min.

Evolución: los ordeños dentro de episodios pasaron de 0 % en julio de 2022 a 5 % en julio de 2024, 27 % en julio de 2025 y 50 % en enero de 2026.

Por Máquina (últimos 3 meses):

Máquina	Relevos pegados (≤ 1 min)	Ordeños en episodios	Episodios por día	Duración mediana del episodio
7063e4b1	68.2 %	40.0 %	6.1	65 min
86696b37	69.2 %	41.6 %	6.2	71 min
b96e85be	76.7 %	55.6 %	7.7	78 min

Qué puede contribuir a la cola

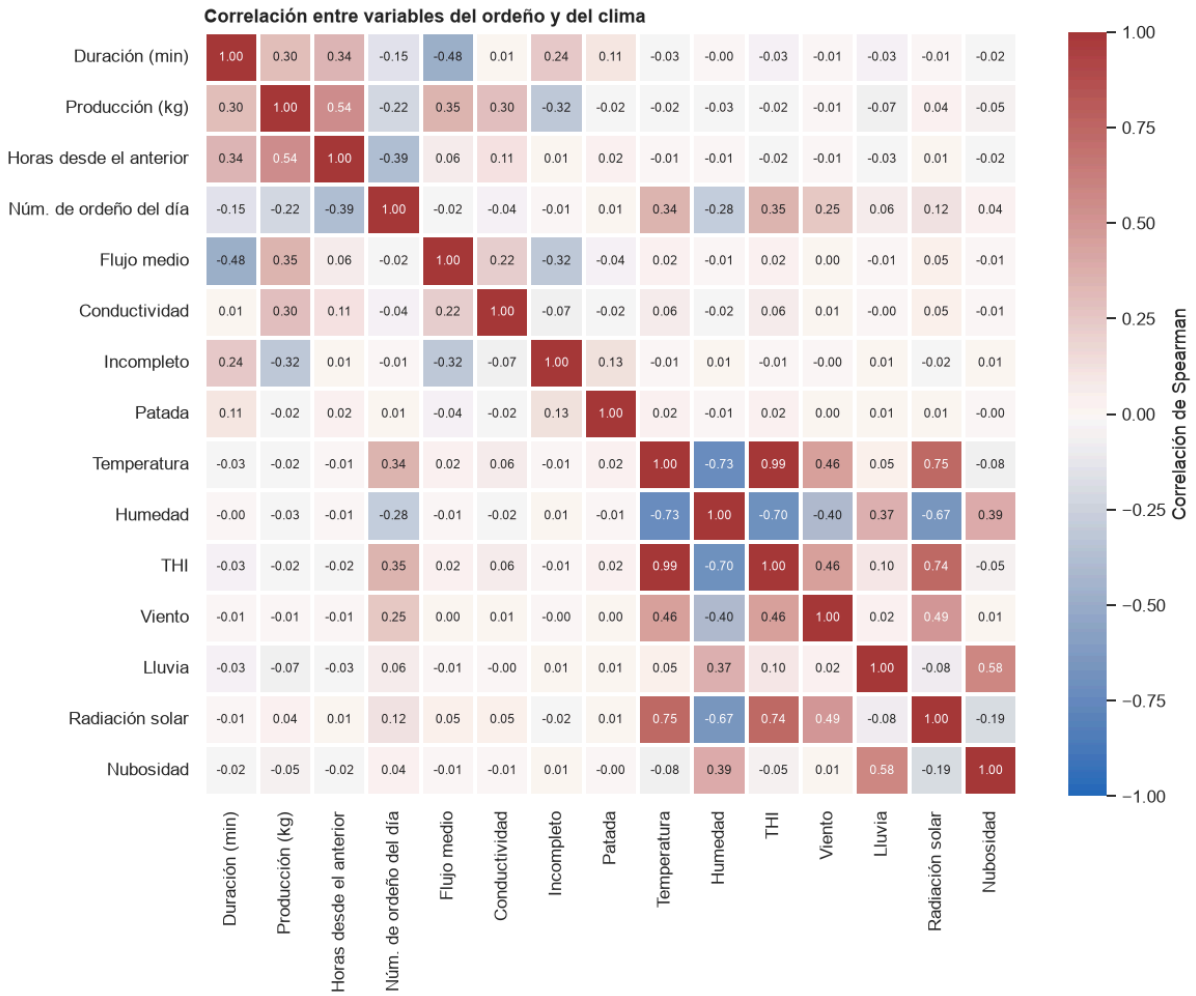
Eventos que ocupan más la máquina: los ordeños con incompleto o pezón no encontrado duran unos 2 min más (mediana de 9.5 y 9.9 min contra 7.4), así que mantienen la máquina ocupada más tiempo y pueden contribuir a la cola.

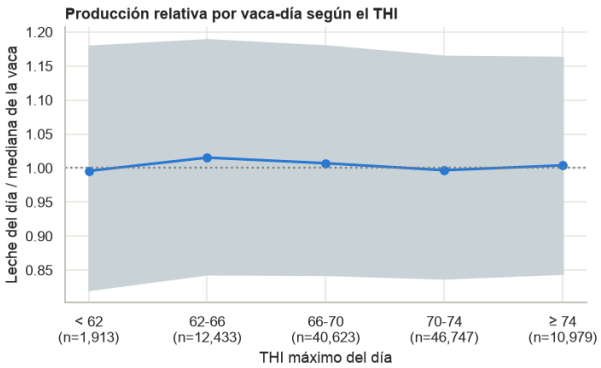
Ordeños largos y poco productivos: 14,046 ordeños superan el percentil 95 de duración de su propia vaca, y 7,449 de ellos (53 %) además tienen producción o flujo bajos. Son candidatos a anomalías que ocupan la máquina sin producir.

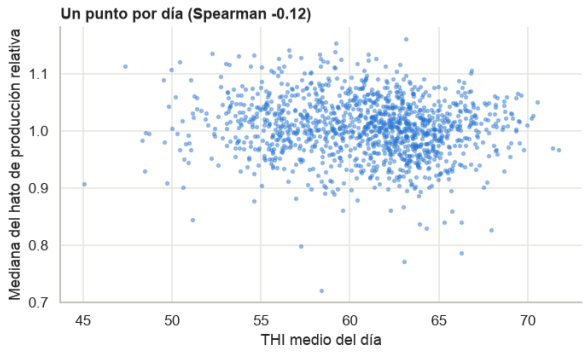
5.4 Clima integrado

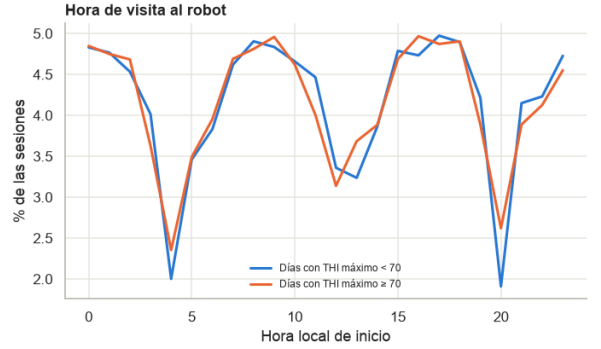
- **Correlación (Spearman) entre el ordeño y el clima de la hora de inicio:** $|r| \leq 0.07$ con producción, duración, flujo, conductividad y los eventos de patada o incompleto; con las 13 variables climáticas, la correlación de cada evento es de 0.03 o menos. Lo que pesa es el propio proceso: la producción sube con las horas desde el ordeño anterior (0.54) y con la duración (0.30) y baja en los ordeños incompletos (−0.32); el flujo medio cae al alargarse el ordeño (−0.48).
- El número de ordeño del día se correlaciona con la temperatura (0.34), probablemente por la hora del día y no por el calor. Temperatura y THI son casi la misma variable (0.99), así que basta usar una.
- La producción relativa de cada vaca baja de 1.0 a 1.1 puntos porcentuales en días calurosos ($p < 0.01$ con THI máximo ≥ 68, 70 y 72); la hora de visita no cambia. La patada sube con el THI de la hora (15.1 % con THI < 55 a 17.6 % con THI ≥ 68); incompleto y pezón no.
- El clima diario tiene mucha redundancia: tres componentes explican 86.6 % (nivel térmico, nubosidad o amplitud, y viento).

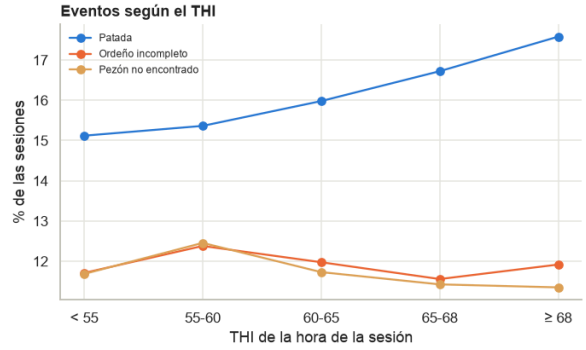
- La producción sube con las horas desde el ordeño anterior (0.54): la mediana por ordeño pasa de unos 10 kg con 4 h a unos 19 kg con 15 h, y después se estabiliza cerca de los 20 kg.


Correlación entre variables del ordeño y del clima
Duración (min)
Producción (kg)
Horas desde el anterior
Núm. de ordeño del día
Flujo medio
Conductividad
Incompleto
Patada
Temperatura
Humedad
THI
Viento
Lluvia
Radiación solar
Nubosidad
Correlación de Spearman
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00


Producción relativa por vaca-día según el THI
Leche del día / mediana de la vaca
THI máximo del día
< 62 (n=1,913)
62-66 (n=12,433)
66-70 (n=40,623)
70-74 (n=46,747)
≥ 74 (n=10,979)


Un punto por día (Spearman -0.12)
Mediana del hato de producción relativa
THI medio del día


Hora de visita al robot
% de las sesiones
Hora local de inicio
Días con THI máximo < 70
Días con THI máximo ≥ 70


Eventos según el THI
Patada
Ordeño incompleto
Pezón no encontrado
% de las sesiones
THI de la hora de la sesión

5.5 Hipótesis iniciales

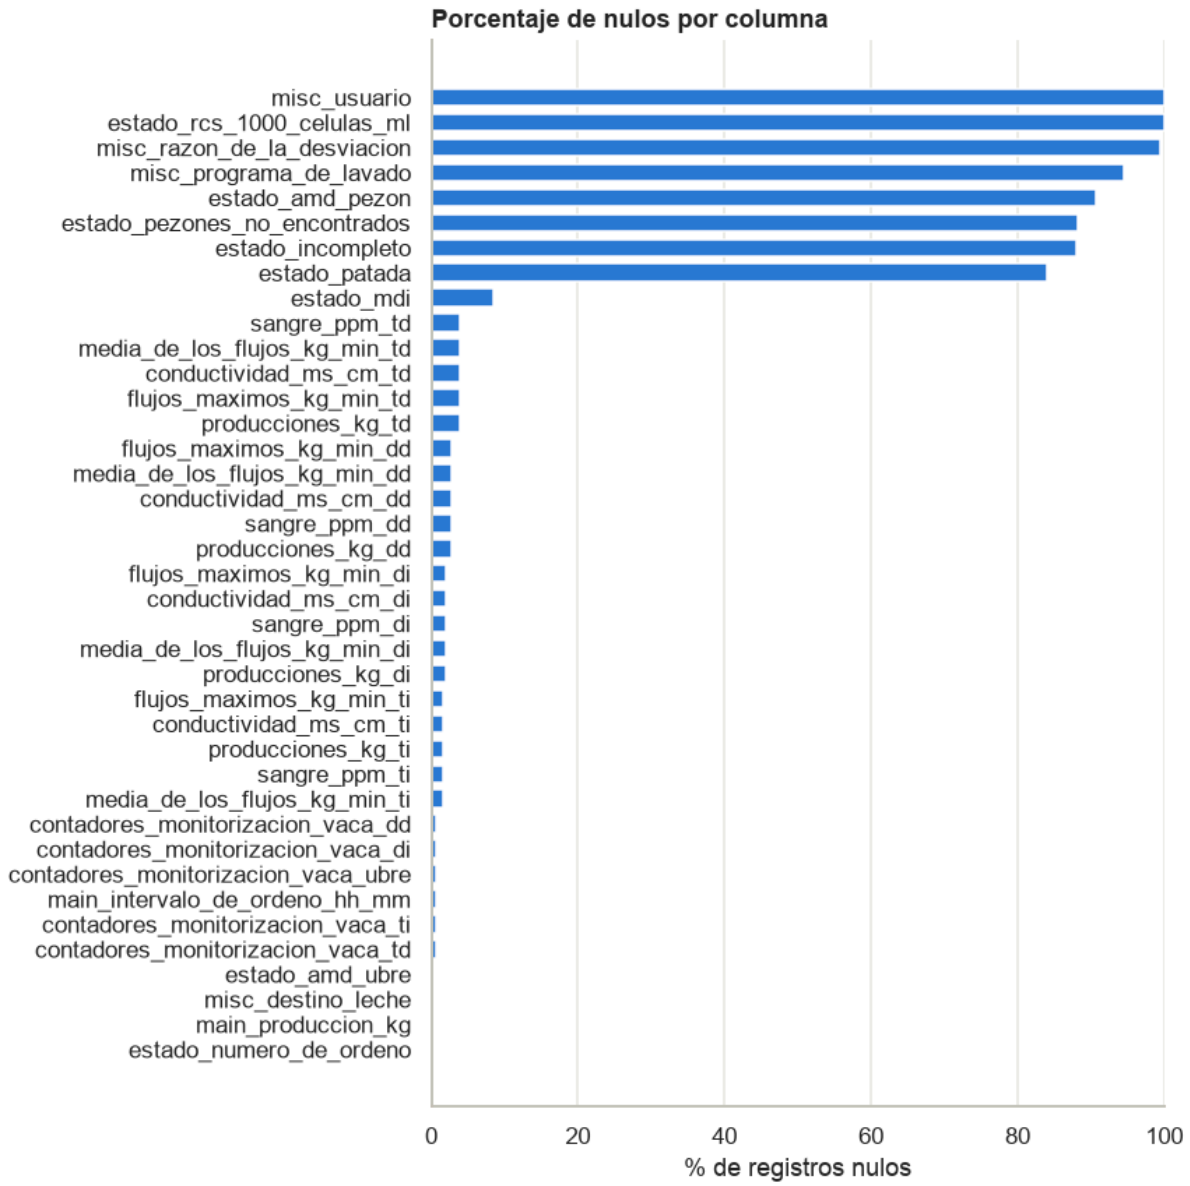
#	Hipótesis	Evidencia	Estado
H1	Con THI alto baja la producción	−1.0 a −1.1 puntos porcentuales ($p < 0.01$)	Débil pero detectable
H2	El calor cambia la hora de las visitas	23.8 % contra 23.6 % entre 0 y 5 h	No sustentada
H3	Los eventos dependen de la máquina y del cuarto	Máquina: efecto despreciable; cuarto en 0 kg en 71 % de incompletos y 87 % de pezones	Parcial
H4	Los eventos se concentran en pocas vacas	El 10 % de las vacas acumula 31 a 38 % de cada evento	Sustentada
H5	Los intervalos cortos se asocian a eventos	Incompleto 32.7 % con intervalo < 4 h	Sustentada (causalidad incierta)
H6	Un evento anticipa el siguiente	39.9 / 30.9 / 37.5 % contra 11.5 / 9.4 / 8.3 %	Sustentada
H7	Las vacas nuevas tienen más eventos	Incompleto de 19 a 23 % (días 7 a 29) contra 11.6 % (≥ 240 días)	Parcial
H8	MDI, conductividad y AMD señalan un mismo problema de ubre	Spearman 0.55; 5.79 contra 5.03 mS/cm	Sustentada como señal
H9	Hay un problema de cola	Ocupación de 13 % a 73.9 %, relevos pegados de 21 % a 80 %	Sustentada con reservas

6. Calidad de los datos

6.1 Análisis de la calidad

Problema	Magnitud	Tratamiento
Sesiones repetidas entre csv y xlsx	5,302 registros (formatos distintos)	Se quitan del csv, se conserva el xlsx
Duplicados exactos	2 pares de rechazos	Eliminar
Columnas vacías o constantes	estado_rcs_1000_celulas_ml (100 % nula), misc_usuario,	Eliminar

Problema	Magnitud	Tratamiento
	misc_programa_de_lavado (94.4 % nula)	
Nulos que significan "no ocurrió"	Alertas: 84 a 91 % de nulos	Convertir a 0/1, no imputar
Nulo estructural	216 visitas que no fueron ordeño	Separar; no imputar
Columnas de una sola fuente	main_intervalo_de_ordeno_hh_mm, contadores_*, estado_mdi (8.4 % de nulos)	Calcular el intervalo con la hora de inicio
Conductividad igual a 0 (imposible)	1.7, 3.2, 8.3 y 28.3 % en DI, DD, TI y TD; en TD, el 89 % de sus ceros viene de la máquina b96e85be (sensor averiado)	Faltante; reportar al cliente
Cero de producción de un cuarto	10.2 % de los ordeños	Dato real (cuarto sin leche); no imputar
Ordeños con 0 kg	164, de los cuales 149 con todos los pezones no encontrados	Conservar y marcar
Total distinto de la suma de cuartos	9 ordeños (> 0.05 kg)	Marcar
Intervalos de más de 48 h	420 (regreso tras un periodo seco)	Faltante, con bandera
Libro de consumo sin ID de vaca	783 eventos	Pendiente



6.2 Datos atípicos

Variable	Límites (1.5 IQR)	Atípicos	Extremos
Producción (kg)	0.52 a 28.65	3,847 (1.37 %)	Máximo 78 kg; 55 ordeños > 40 kg
Duración (min)	1.52 a 14.12	7,683 (2.74 %)	Máximo 55.8 min; 31 ordeños > 30 min
Intervalo (h)	1.07 a 17.99	10,173 (3.63 %)	420 de más de 48 h

Otros atípicos: sangre de hasta 8,000 ppm (solo 1.1 % pasa de 1,000), MDI de hasta 15.36, 14,046 ordeños largos para su vaca (7,449 con producción o flujo bajos) y picos por máquina (caída de ordeños de 7063e4b1 en marzo de 2024). **No**

se eliminan: pueden ser justo las anomalías a detectar; se transforman (logaritmo) o se usan métodos robustos.

6.3 Métodos de limpieza recomendados

#	Acción	Estado
1	Convertir fechas, duración e intervalo a datetime y número (los intervalos de Excel se leen como fecha)	Aplicada
2	Quitar las 5,302 sesiones repetidas entre csv y xlsx y los 2 duplicados exactos	Aplicada
3	Eliminar columnas vacías o constantes	Aplicada
4	Separar los 216 rechazos y echadas sin ordeñar; dejar fuera la máquina con 2 registros	Aplicada
5	Convertir las alertas de texto a banderas 0/1 por cuarto	Aplicada
6	Conductividad 0 → faltante; en el cuarto trasero derecho de b96e85be, calcular la razón de conductividad solo con cuartos válidos o excluir ese cuarto	Parcial
7	Intervalos de más de 48 h → NaN y bandera "regreso tras periodo seco"	Parcial
8	No imputar cuartos sin leche ni nulos estructurales; MDI y sensores: manejo de nulos del modelo o imputación por vaca, sin imputación múltiple ciega	Parcial
9	Conservar y marcar los 164 ordeños con 0 kg y los 9 con suma de cuartos distinta	Por aplicar
10	No eliminar atípicos: logaritmo o métodos robustos	Por aplicar
11	Rezagos y promedios móviles por vaca con desplazamiento de un ordeño (sin filtrar el presente), reiniciando tras ausencias de 45 días o más	Por aplicar
12	Excluir del historial por vaca a las que tienen menos de 30 registros	Por aplicar
13	Clima: desfase de una hora, THI por hora, máximo diario y rezagos	Parcial
14	Definir las clases (prioridad o etiquetas múltiples) antes de construir el objetivo	Por aplicar

#	Acción	Estado
15	Normalizar o marcar la sangre por máquina (picos de 27.8 % y máximos de 8,000 ppm)	Por aplicar

7. Implicaciones para el modelado

1. **Definir las clases con cuidado.** El incompleto y el pezón no encontrado casi coinciden; no usar uno para predecir el otro.
2. **Evitar la fuga de información.** Duración, producción, conductividad, flujo, cuartos en 0 kg, destino de la leche y razón de desviación se miden en la misma sesión y pueden ser consecuencia del evento; para una alerta temprana usar el intervalo previo, el historial de la vaca y el clima.
3. **Aprovechar el historial de la vaca** (evento previo, tasa propia): es la señal más clara.
4. **Validar por tiempo**, con precisión, sensibilidad y F1 además del accuracy.
5. **Clima como variable de contexto** (THI máximo del día, rezagos, nubosidad y viento), sin esperar que sea la señal principal.8. Pendientes con el socio formador

- El sensor de conductividad del cuarto trasero derecho de b96e85be.
- Los picos de sangre y la caída de 7063e4b1 en 2024.
- El umbral de conductividad (6.5 mS/cm por confirmar).
- La definición de incomplete, teat_missing y kick.
- La fecha de parto (no hay fecha de parto ni etiquetas de salud: la lactancia se aproxima por brechas de registro).
- Si existe un registro de llegada a la fila.

Anexo: calidad por columna de los historiales CSV

Perfil de las 7,247 filas de los historiales CSV (34 vacas), con el clima ya unido.

Variable	Tipo de dato	No nulos	Faltantes	% faltantes	Valores únicos
id_vaca	str	7247	0	0.00%	34
main_hora_de_inicio	str	7247	0	0.00%	7141
main_accion	str	7247	0	0.00%	3
main_duracion_mm_ss	str	7247	0	0.00%	803
main_produccion_kg	float64	7016	231	3.19%	2120
estado_numero_de_ordeno	float64	7016	231	3.19%	5

Variable	Tipo de dato	No nulos	Faltantes	% faltantes	Valores únicos
estado_rcs_1000_celulas_ml	float64	0	7247	100.00%	0
estado_patada	str	1299	5948	82.08%	15
estado_incompleto	str	1014	6233	86.01%	15
estado_pezones_no_encontrados	str	1239	6008	82.90%	15
estado_amd_ubre	float64	7016	231	3.19%	2
estado_amd_pezon	str	802	6445	88.93%	14
media_de_los_flujos_kg_min_di	float64	7016	231	3.19%	43
media_de_los_flujos_kg_min_dd	float64	7013	234	3.23%	44
media_de_los_flujos_kg_min_ti	float64	6717	530	7.31%	48
media_de_los_flujos_kg_min_td	float64	6952	295	4.07%	48
sangre_ppm_di	float64	7016	231	3.19%	110
sangre_ppm_dd	float64	7013	234	3.23%	84
sangre_ppm_ti	float64	6717	530	7.31%	120
sangre_ppm_td	float64	6952	295	4.07%	60
conductividad_ms_cm_di	float64	7016	231	3.19%	372
conductividad_ms_cm_dd	float64	7013	234	3.23%	291
conductividad_ms_cm_ti	float64	6717	530	7.31%	308
conductividad_ms_cm_td	float64	6952	295	4.07%	358
misc_eo_po	str	7247	0	0.00%	3
misc_usuario	float64	0	7247	100.00%	0
misc_destino_leche	str	7016	231	3.19%	3
misc_razon_de_la_desviacion	str	1	7246	99.99%	1

Variable	Tipo de dato	No nulos	Faltantes	% faltantes	Valores únicos
flujos_maximos_kg_min_di	float64	7016	231	3.19%	58
flujos_maximos_kg_min_dd	float64	7013	234	3.23%	55
flujos_maximos_kg_min_ti	float64	6717	530	7.31%	80
flujos_maximos_kg_min_td	float64	6952	295	4.07%	66
producciones_kg_di	float64	7016	231	3.19%	755
producciones_kg_dd	float64	7013	234	3.23%	687
producciones_kg_ti	float64	6717	530	7.31%	835
producciones_kg_td	float64	6952	295	4.07%	928
t2m	float64	7247	0	0.00%	1601
rh2m	float64	7247	0	0.00%	2398
t2mdew	float64	7247	0	0.00%	1581
t2mwet	float64	7247	0	0.00%	1249
qv2m	float64	7247	0	0.00%	1114
ps	float64	7247	0	0.00%	111
ws2m	float64	7247	0	0.00%	586
ws10m	float64	7247	0	0.00%	711
wd10m	float64	7247	0	0.00%	1715
prectotcorr	float64	7247	0	0.00%	134
allsky_sfc_sw_dwn	float64	7247	0	0.00%	377
allsky_sfc_lw_dwn	float64	7247	0	0.00%	73
cloud_amt	float64	7247	0	0.00%	1798

8. Glosario

Aquí está la tabla en orden alfabético (se ignoran paréntesis y símbolos al ordenar):

Variable	Tipo de dato
***Accuracy* (exactitud)**	Porcentaje de predicciones correctas. Es engañosa con clases desbalanceadas.
AMD (ubre / pezón)	Alerta del sistema DeLaval asociada a la ubre o al pezón.
Anonimización / *hash*	Sustitución de los identificadores reales de vacas y máquinas por códigos irreversibles (id_vaca, misc_eo_po).
Conductividad (mS/cm)	Conductividad eléctrica de la leche por cuarto. Valores altos suelen indicar problemas de salud de la ubre. En el documento, 0 se trata como faltante.
Correlación de Spearman	Correlación basada en rangos. Mide relaciones monótonas aunque no sean lineales.
Cuartos (DI, DD, TI, TD)	Las cuatro secciones de la ubre: delantero izquierdo, delantero derecho, trasero izquierdo y trasero derecho.
Divert (1 a 3) / Drenaje	Destinos alternos de la leche. "Divert" es leche desviada del tanque (por ejemplo, por sangre) y "Drenaje" es leche descartada.
Etapa de lactancia	Momento del ciclo productivo de la vaca (pico tras el parto y descenso gradual). Se aproxima con las ausencias porque no hay fecha de parto.
Evento	Cualquiera de las cuatro banderas de anomalía: patada, incompleto, pezón no encontrado y AMD de pezón.
Hueco	Tiempo entre el fin de un ordeño y el inicio del siguiente en la misma máquina.
Imputación	Rellenar valores faltantes con estimaciones.
Instancia	Fila en la tabla donde se tienen los registros de las vacas.
Intervalo de ordeño	Horas desde el ordeño anterior de la misma vaca.
IQR	Rango intercuartílico (Q3 − Q1): medida de dispersión usada para fijar los límites de atípicos.
MDI	*Mastitis Detection Index*: índice del sistema DeLaval que señala posible mastitis (inflamación de la ubre).

NASA POWER	Fuente externa de datos climáticos horarios por celda geográfica (≈ 55 × 65 km). Aporta las 13 variables de clima.
Ordeño incompleto	Ordeño que terminó antes de extraer toda la leche esperada.
Ordeño voluntario	La vaca decide cuándo entra al robot, sin horario fijo de ordeño.
PCA	Análisis de componentes principales: reduce muchas variables correlacionadas a pocos componentes.
Patada	Evento en que la vaca patea durante el ordeño.
Periodo seco	Ausencia larga de la vaca (más de 40 días, mediana de 81) durante la cual no se ordeña. No equivale a producción cero.
Precisión, sensibilidad y F1	Precisión: de las alertas emitidas, cuántas son reales. Sensibilidad: de los eventos reales, cuántos se detectan. F1: media armónica de ambas.
RCS	Recuento de células somáticas de la leche. En los datos está 100 % vacío.
Rechazo	Visita en la que el sistema no deja ordeñar a la vaca. Solo se registra en 2025.
Sangre (ppm)	Concentración de sangre detectada en la leche por cuarto, en partes por millón.
THI	*Temperature-Humidity Index* (Índice de Temperatura-Humedad). Mide el estrés por calor de las vacas a partir de la temperatura y la humedad. En el documento, THI ≥ 68 se toma como día o hora caluroso.
V de Cramér	Medida de relación (0 a 1) entre dos variables categóricas.
Valor atípico (*outlier*)	Valor muy alejado del resto. Se detecta con la regla de 1.5 × IQR y no se elimina porque puede ser la anomalía buscada.
VIF	Factor de inflación de la varianza: detecta multicolinealidad entre variables. Valores bajos (aquí, máximo 2.84) indican que no hay problema grave.
Pollaczek-Khinchine	Fórmula de la teoría de colas que estima el tiempo promedio de espera en una fila con un solo servidor (cola M/G/1). Supone llegadas al azar, una vaca atendida a la vez y

	duraciones de servicio variables. Usa la ocupación de la máquina (ρ), la duración media del ordeño (E[S]) y la variabilidad de esa duración (CV). En este proyecto sirve para aproximar cuánto espera una vaca para ordeñarse, ya que el sistema no registra su llegada a la fila.
Cola M/G/1	Modelo de fila con llegadas al azar, tiempos de servicio de cualquier distribución y un solo servidor. En este proyecto, cada máquina de ordeño se trata como un servidor independiente.