Reporte: Modelado de los datos

Por PINU

Adaptaciones de la metodología CRISP-DM..... 1
Construcción del modelo de regresión logística..... 1
Construcción del modelo XGBoost..... 1
Hiperparametros usados..... 1
Evaluación del desempeño del modelo..... 2
Interpretación de los resultados..... 8
Dificultades identificadas..... 9
Construcción del modelo LSTM..... 9
Reporte de diseño de pruebas..... 10

Adaptaciones de la metodología CRISP-DM

Se adaptó la metodología para explicar en el reporte de construcción del modelo cualquier modificación al formato de los datos, en lugar de regresar a la actividad reporte de formato de datos de la fase de preparación de los datos.

Se mueve la selección del modelo al reporte de Data Preparation para tener coherencia con la explicación de las variables seleccionadas.

Construcción del modelo de regresión logística

TBD

Construcción del modelo XGBoost

Hiperparametros usados

Hiperparámetro	**Valor**
n_estimators	100
learning_rate	0.3
max_depth	6
min_child_weight	1
gamma	0
*subsample, colsample_by**	1
reg_lambda / reg_alpha	1 / 0

Hiperparámetro	**Valor**
tree_method	histograma (max_bin 256)
objective	binary:logistic
scale_pos_weight	6.35 (mecánica), 4.38 (salud), 5.37 (conducta)
random_state	42
Early stopping	no

- *scale_pos_weight* es el cociente negativos / positivos de train. Compensa el desbalance.
- Entran 280,602 ordeños (sin los 231 rechazos y echadas) y los 39 atributos de la tabla de selección, con los NaN sin imputar.

Además, se hizo un corte cronológico del 70/15/15

Conjunto	**Sesiones**	**Periodo**	**Prevalencia mecánica / salud / conducta**
Train	196,421	13/07/2022 – 01/06/2025	13.6 % / 18.6 % / 15.7 %
Val	42,090	01/06/2025 – 05/10/2025	17.0 % / 19.1 % / 17.4 %
Test	42,091	05/10/2025 – 28/01/2026	14.5 % / 21.3 % / 16.4 %

Evaluación del desempeño del modelo

Hay una tabla por evento. Las métricas con umbral usan el de val. «Accuracy base» es la de responder siempre «sin evento». La columna «Por vaca» es la media de los 5 folds.

Falla mecánica

Métrica	Train	Val	Test	Por vaca
ROC-AUC	0.897	0.808	**0.803**	0.813 ± 0.015
PR-AUC	0.640	0.550	**0.524**	0.489 ± 0.078
Brier	0.132	0.176	0.145	0.150
Accuracy	74.5 %	67.6 %	**74.0 %**	72.1 %
Accuracy base	86.4 %	83.0 %	85.5 %	—
Precisión	33.6 %	32.0 %	32.5 %	30.5 %
Recall	88.9 %	80.0 %	**73.1 %**	76.2 % ± 4.1
F1	0.487	0.457	0.450	0.436

Anomalía de salud

Métrica	Train	Val	Test	Por vaca
ROC-AUC	0.945	0.885	**0.880**	0.903 ± 0.012
PR-AUC	0.839	0.705	**0.733**	0.750 ± 0.030
Brier	0.091	0.120	0.129	0.111
Accuracy	85.6 %	81.2 %	**79.8 %**	82.7 %
Accuracy base	81.4 %	80.9 %	78.7 %	—
Precisión	57.2 %	50.5 %	51.7 %	53.1 %
Recall	88.7 %	80.0 %	**80.8 %**	82.3 % ± 1.6
F1	0.695	0.619	0.630	0.645

Interrupción por conducta

Métrica	Train	Val	Test	Por vaca
ROC-AUC	0.874	0.766	**0.792**	0.791 ± 0.018
PR-AUC	0.609	0.475	**0.501**	0.481 ± 0.041
Brier	0.147	0.170	0.163	0.167

Métrica	Train	Val	Test	Por vaca
Accuracy	64.6 %	59.6 %	**61.5 %**	60.8 %
Accuracy base	84.3 %	82.6 %	83.6 %	—
Precisión	29.8 %	27.4 %	27.5 %	26.7 %
Recall	92.6 %	80.0 %	**81.7 %**	83.2 % ± 5.4
F1	0.451	0.409	0.411	0.404

Con umbral 0.5, la accuracy en test sube a 80.9 / 82.0 / 76.4 % y el recall baja a 65.3 / 77.3 / 64.3 %.

Criterios del BU en test

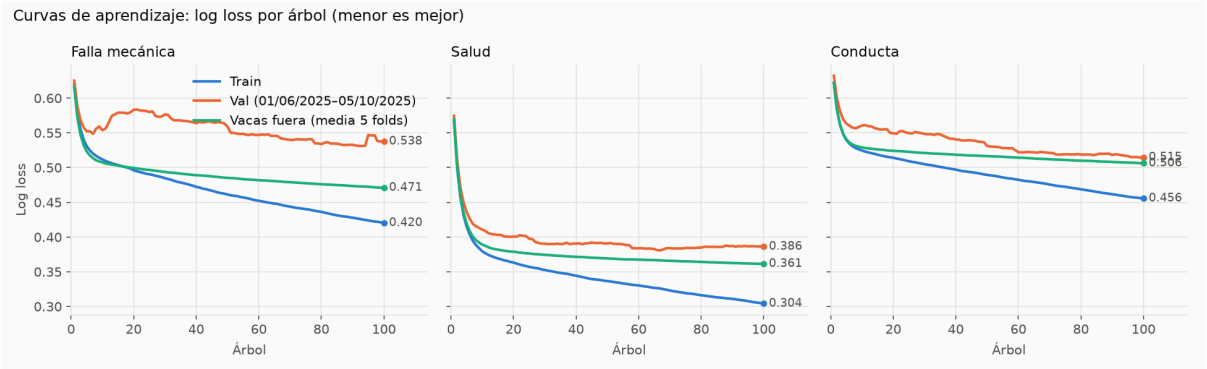
Criterio	Mecánica	Salud	Conducta
Recall ≥ 80 %	73.1 %	80.8 %	81.7 %
Accuracy ≥ 70 %	74.0 %	79.8 %	61.5 %
ROC-AUC train − test	0.094	0.065	0.082

De esta última tabla, podemos destacar que:

- **Ningún evento cumple los dos criterios con margen.** Salud cumple ambos, pero su accuracy apenas supera a la base (79.8 % contra 78.7 %). En mecánica y conducta, la accuracy del modelo queda por debajo de la base.
- **Hay sobreajuste moderado.** El log loss de train sigue bajando mientras el de val se queda casi plano (gráfica 1). Aun así, val y test rinden parecido.
- **El corte por vaca da cifras cercanas al test cronológico.** En mecánica los folds varían más: el PR-AUC va de 0.35 a 0.55.

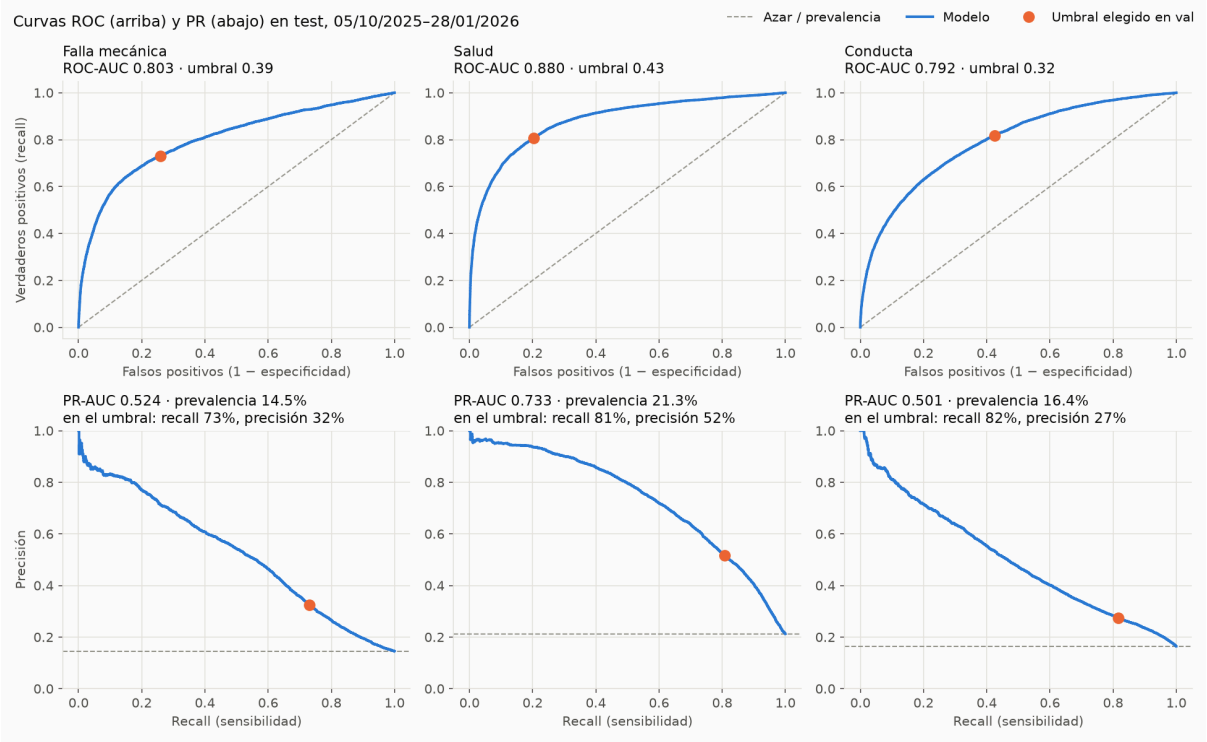
Gráficos

Curvas de aprendizaje



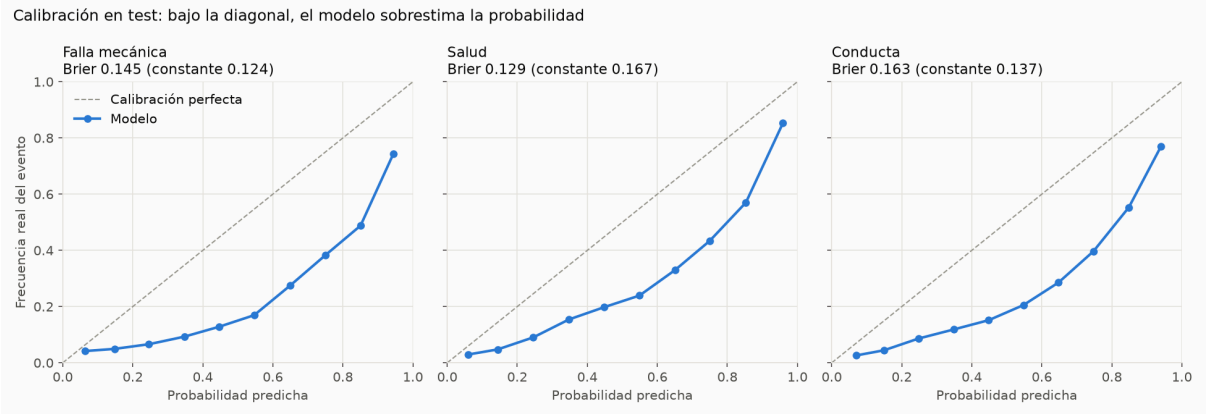
En los tres eventos, la pérdida de train baja hasta el árbol 100, mientras que la de val baja mucho más despacio a partir del árbol 20 a 40, o se queda plana, como en salud. La brecha final (0.12 en mecánica, 0.08 en salud y 0.06 en conducta) es el sobreajuste moderado que muestra la tabla. En mecánica, val incluso empeora entre los árboles 8 y 20 antes de recuperarse despacio, así que un early stopping se habría detenido muy pronto. La curva de vacas fuera (verde) queda entre train y val. Que val quede por encima de ella sugiere que cambiar de periodo afecta más al modelo que cambiar de vacas.

ROC y PR en test



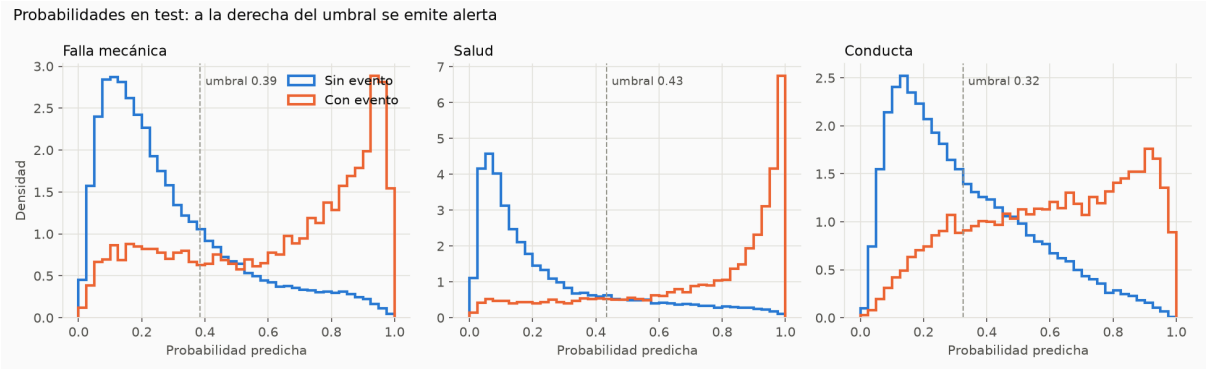
En las curvas ROC, salud sube más rápido: con 20 % de falsos positivos ya detecta 80 % de los eventos. Mecánica y conducta necesitan más falsos positivos para llegar al mismo recall; por eso conducta alcanza 82 % de recall a costa de 43 % de falsos positivos. Las curvas PR muestran que las alertas con probabilidad más alta sí son confiables. En salud, la precisión se mantiene arriba de 90 % hasta 20–30 % de recall, y en mecánica y conducta empieza cerca de 80 %. En el umbral de val, en cambio, la precisión baja a 32 % en mecánica, 52 % en salud y 27 % en conducta. Como referencia, la línea punteada es la prevalencia, que equivale a la precisión de alertar al azar.

Calibración en test



Las tres curvas quedan por debajo de la diagonal en todo el rango, así que el modelo sobrestima la probabilidad. Por ejemplo, cuando predice 0.6, el evento ocurre solo entre 20 % y 30 % de las veces. La causa es *scale_pos_weight*, que infla a propósito el peso de los positivos. Por eso, en mecánica y conducta el Brier del modelo es peor que el de predecir siempre la prevalencia (0.145 contra 0.124 y 0.163 contra 0.137).

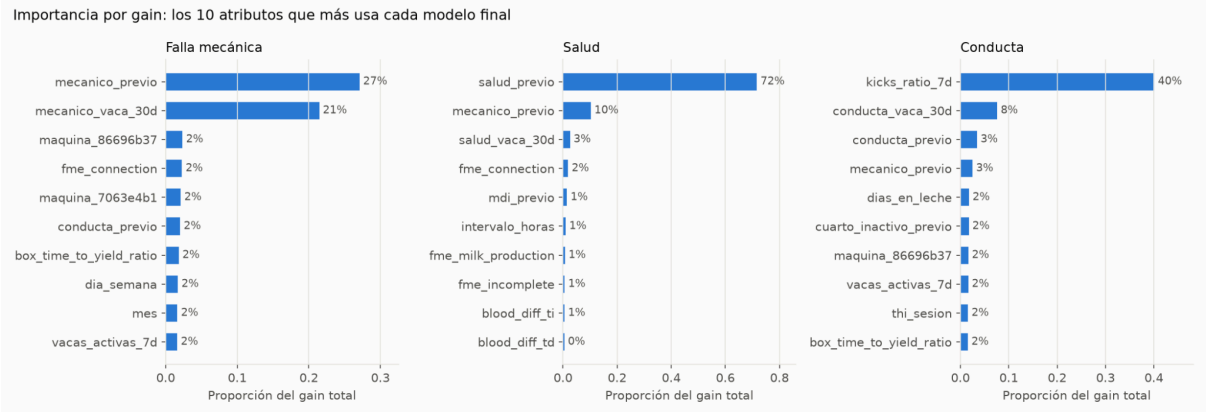
Distribución de probabilidades en test



Los ordeños sin evento (azul) se concentran en probabilidades bajas, de 0.05 a 0.2, con una cola larga hacia la derecha; esa cola son las falsas alarmas. En salud y mecánica, los ordeños con evento (naranja) forman dos grupos. El primero es un

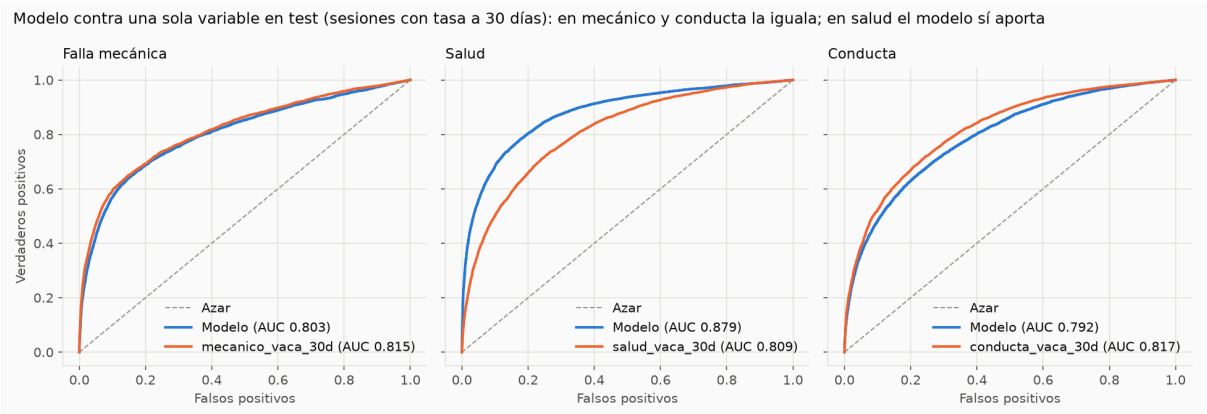
pico cerca de 0.9–1.0: son los que el modelo anticipa con seguridad, por el peso de las variables **_previo*. El segundo es una franja plana entre 0 y 0.5: son eventos sin aviso previo, y ahí están los que no se detectan. En conducta, los eventos se reparten y se enciman con los ordeños sin evento entre 0.3 y 0.7, y por eso es el evento con menor precisión.

Importancia por gain



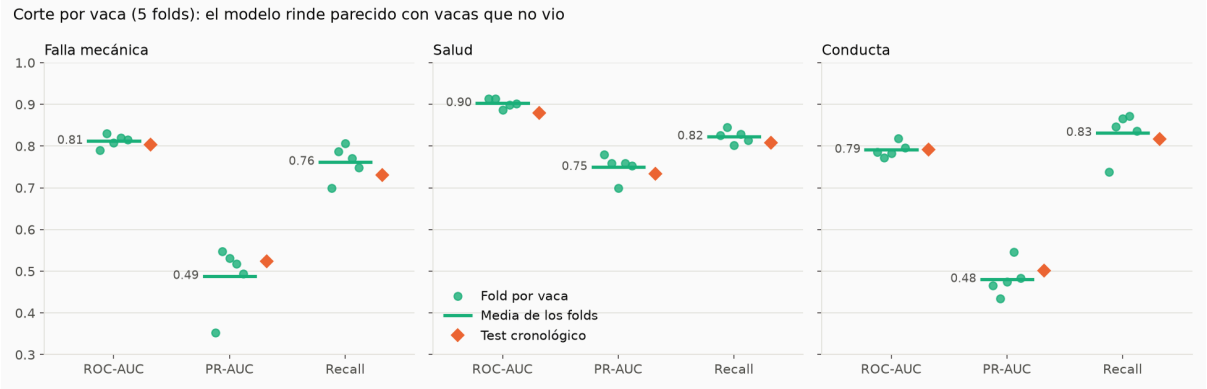
En cada evento hay una o dos variables que concentran casi todo el gain. En salud, *salud_previo* reúne el 72 %, seguida de *mecanico_previo* con 10 %. En mecánica pesan *mecanico_previo* (27 %) y *mecanico_vaca_30d* (21 %), y en conducta, kicks_ratio_7d (40 %) y *conducta_vaca_30d* (8 %). Fuera de las dos primeras de cada evento, ninguna variable pasa de 3 %. El clima aporta poco, como ya anticipaba el DU, y el calendario y la carga del hato (*vacas_activas_7d*) no pasan de 2 %. El gain solo dice qué variables usa el modelo, no en qué dirección empujan la predicción.

ROC del modelo frente a la tasa del evento de la vaca en 30 días, usada sola



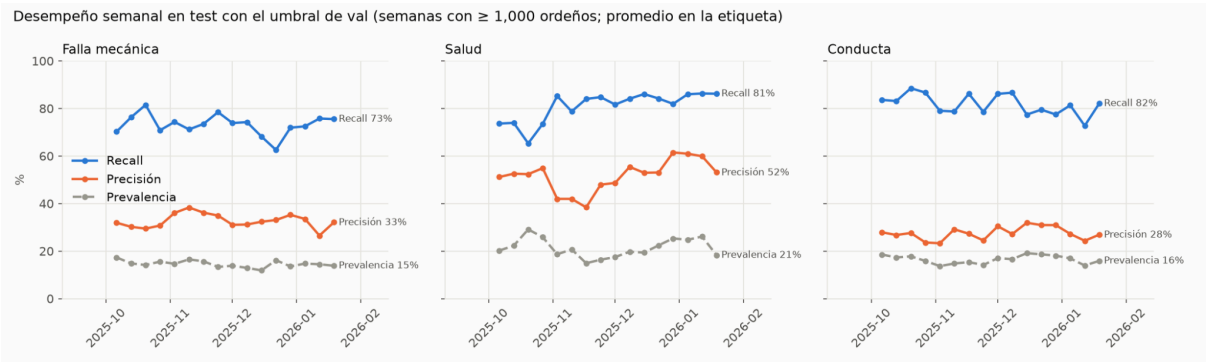
La comparación usa solo las sesiones de test que ya tienen calculada la tasa a 30 días. En mecánica y conducta, esa tasa usada sola iguala o supera al modelo: 0.815 contra 0.803 en mecánica y 0.817 contra 0.792 en conducta. Es decir, con los valores por defecto, los 39 atributos juntos no superan a esa variable sola. En salud, en cambio, el modelo sí aporta (0.879 contra 0.809), gracias a *salud_previo* y a las demás variables.

Corte por vaca



Los 5 folds de cada evento quedan agrupados y el test cronológico (rombo) cae cerca de su media, así que el modelo rinde parecido con vacas que no vio y con fechas que no vio. Hay dos folds que se salen: uno de mecánica, con PR-AUC 0.35 y recall 0.70, y uno de conducta, con recall 0.74. Eso indica que hay grupos de vacas con los que el modelo funciona peor.

Desempeño semanal en test



Ningún evento se degrada de forma sostenida en los casi 4 meses de test. En salud, el recall sube de cerca de 70 % en octubre a 80–86 % desde noviembre, y la precisión baja a cerca de 40 % a mediados de noviembre, cuando la prevalencia cae a 15 %. En mecánica, el recall oscila entre 62 % y 81 % y queda casi siempre por debajo de 80 %, igual que en el total. Conducta es el más estable, entre 73 % y 88 %. En los tres eventos, la precisión de cada semana sigue a su prevalencia: cuando hay menos eventos, una parte mayor de las alertas son falsas.

Interpretación de los resultados

El modelo aprende sobre todo la persistencia de cada vaca. Las variables de historial concentran casi todo el gain, y en mecánica y conducta la tasa de la vaca a 30 días, usada sola, rinde igual que el modelo (gráficas 5 y 6). Salud es el único evento en el que el modelo supera claramente a esa regla, y también el que mejor se predice, con un PR-AUC de 0.73 en test. Conducta es el más difícil, con 0.50. Lo que el modelo no detecta son, sobre todo, los eventos sin aviso previo, que quedan con probabilidades bajas (gráfica 4).

Llegar al 80 % de recall cuesta precisión. Por cada evento real detectado hay unas 2 falsas alarmas en mecánica, casi 3 en conducta y alrededor de 1 en salud. Además, la salida sirve para ordenar los ordeños por riesgo, pero todavía no como la probabilidad que pide el BU, porque está descalibrada (gráfica 3).

Dificultades identificadas

1. El umbral de val no se transfiere a test en mecánica. Val (junio a octubre) tiene más eventos mecánicos (17.0 %) que train (13.6 %) y que test (14.5 %). Por eso, el umbral que en val da 80 % de recall solo da 73.1 % en test.
2. No se puede cumplir a la vez recall ≥ 80 % y una accuracy útil. Subir el recall baja la accuracy por debajo de la base en mecánica y conducta, y la precisión de conducta queda en 27.5 %.
3. Sobreajuste sin early stopping ni ajuste de hiperparámetros.
    a. Hay una brecha de 0.06–0.09 en ROC-AUC entre train y test.
    b. En mecánica, el log loss de val sube entre los árboles 8 y 20 antes de volver a bajar.
4. En mecánica y conducta, el modelo no supera a la tasa de la vaca a 30 días usada sola (gráfica 6). Con la configuración por defecto, las demás variables no aportan nada medible en esos dos eventos.
5. Las probabilidades no están calibradas por *scale_pos_weight*.

Construcción del modelo LSTM

TBD

Reporte de diseño de pruebas

En este reporte se define cómo se entrenan, ajustan y evalúan los tres modelos elegidos para el proyecto: regresión logística, XGBoost y LSTM. De igual forma, se definen los cortes de datos, los conjuntos, los pasos de entrenamiento, el número de iteraciones y la prueba de cada criterio de éxito, para que los resultados de los tres modelos sean comparables.

El objetivo de minería de datos es clasificar los posibles tipos de evento que se presentan en el ordeño, y es por eso que cada modelo tiene cuatro salidas: evento de falla mecánica, anomalía de salud, interrupción por conducta, y “alguna anomalía”, la probabilidad de que el ordeño no sea exitoso.

Criterio de BU	**Qué se mide**	**Qué datos**	**Se cumple si**
Identificar al menos el 80% de las sesiones de ordeño que presenten anomalías.	Sensibilidad (recall): de los ordeños de test que sí tuvieron una anomalía, el porcentaje en el que el modelo dio una alerta. El modelo da una alerta cuando la probabilidad que calcula supera un umbral; tal umbral se fija con el conjunto de validación y se aplica sin cambios en test. Se mide para la salida “alguna anomalía” y para cada evento por separado.	Test	La sensibilidad de “alguna anomalía” es de al menos 80%. La de cada evento se reporta, pero no decide el criterio.
Mantener un accuracy (detectar que es una anomalía) de al menos el 80% en la detección de anomalías	Accuracy: porcentaje de ordeños de test que el modelo clasifica bien (da alerta cuando hubo anomalía y no la da cuando no hubo), con el mismo umbral de la fila anterior. Se compara con la accuracy base, que es la que tendría un modelo que nunca da alertas. Por ejemplo, si el 14.5% de los ordeños tiene falla mecánica, no alertar nunca ya acierta en el 85.5%.	Test	La accuracy es mayor o igual a 80 y también es mayor que la accuracy base.
Mostrar los 3 factores que más influyeron en la predicción del evento de al menos el 80% de las veces.	Porcentaje de alertas de test en las que el modelo puede mostrar 3 variables distintas que aumentaron la probabilidad de anomalía. Las columnas que vienen de una misma variable, como los rangos de días en leche o los pasos de la secuencia de la LSTM, se suman como una sola.	Todas las alertas de test	El porcentaje es mayor o igual al 80% de las alertas
Identificar los factores que provocan las anomalías en al menos un 80% de las veces.	Porcentaje de alertas revisadas en las que el socio formador considere que los 3 factores son una explicación coherente del evento, según su conocimiento del proceso de ordeño. Como el	Muestra de alertas de test	El porcentaje es mayor o igual al 80% de las alertas revisadas

	modelo solo detecta asociaciones, esta prueba no demuestra que los factores causen la anomalía.		

Como los eventos son poco frecuentes, la accuracy por sí misma no distingue un buen modelo de uno que nunca alerta, como se vio en el entendimiento de los datos. Por eso la métrica principal para comparar modelos es el PR-AUC, que no depende del umbral, y las métricas con umbral se reportan siempre junto con la accuracy base.

Partición de los datos

Los tres modelos usan un solo corte cronológico de 70/15/15. Las sesiones se ordenan por fecha de inicio, con el 70% más antiguo siendo el conjunto de entrenamiento, el 15% siguiente el de validación, y el 15% más reciente el de prueba. Entre cada conjunto se dejan 7 días sin usar, como se indica en el reporte de selección del modelo.

Conjunto	**Periodo**	**Sesiones**	**Uso**
Entrenamiento	13/07/2022 - 31/05/2025	196,421	Ajustar los parámetros de cada modelo.
Espacio 1	01/06/2025 - 07/06/2025	-	No se usa para entrenar ni para evaluar, sólo como historial.
Validación	08/06/2025 - 04/10/2025	42,090	Elegir hiperparámetros, detener el entrenamiento (early stopping), calibrar las probabilidades y fijar el umbral de alerta.
Espacio 2	05/10/2025 - 11/10/2025	-	Igual que el espacio 1.
Test	12/10/2025 - 28/01/2026	42,091	Medición final, una sola vez por modelo.

Se usa un corte por fecha y no al azar porque así la prueba imita el uso real, entrenando el modelo con el pasado y evaluándolo con ordeños que todavía no conocía. Además, los ordeños seguidos de una misma vaca casi no cambian, y con un corte al azar el modelo acertaría por reconocerlos (ver reporte de selección del modelo). No se usa un segundo tipo de corte (por ejemplo, por vaca) porque los tres modelos deben compararse exactamente con los mismos datos, y repetir varios cortes en la LSTM multiplicaría su tiempo de entrenamiento. En su lugar, el desempeño con vacas nuevas se mide como un subconjunto del test (ver abajo).

Reporte aún sin terminar (pendiente)