

Tecnológico de Monterrey

Reto Datos

Manuel Bajos Rivera A01711581

Yael Charles Marin A01711111

Mauricio Olguin Sanchez A01711522

Marco Iván Flores Villanueva A01276586

Emilio Santiago López Quiñonez A01711977

Alejandro Adrian Garcia Martinez A01707109

22 de Octubre del 2025

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Profesor: Ismael Solís Moreno

Tecnológico de Monterrey

Herramientas y tecnologías para el proyecto

Las tecnologías que usaremos para el desarrollo del proyecto serán las siguientes:

- Python (pandas y numpy, Scikit-learn, keras)
- IDE personal (VS Code)
- AWS (si requiere despliegue)
- API NASA (Datos del clima)
- GitHub
- Google Drive

Consideramos que estas tecnologías elegidas son ideales para nuestro proyecto, pues son ampliamente utilizadas en la industria y juntas pueden conformar un flujo de trabajo completo en el marco de CRISP-DM, que es la metodología que tomamos y adaptamos para el equipo. Nuestra librería de ciencia de datos elegida, Scikit-learn, es líder en adopción entre frameworks de machine learning según la encuesta Kaggle 2022, realizada a 23997 profesionales de 173 países, y mantiene una adopción muy alta entre desarrolladores según Stack Overflow. Su escala de distribución, más de 2000 millones de descargas anuales según datos de PyPI analizados en 2026, también refuerza esa posición.

Por otro lado, Python, el lenguaje base del proyecto, se ha consolidado como el estándar para inteligencia artificial y ciencia de datos. Según la encuesta de desarrolladores de Stack Overflow 2025, su uso creció 7 puntos porcentuales en un año hasta alcanzar el 57.9% de los encuestados, su mayor crecimiento en años, en un estudio que consideró cerca de 49000 respuestas válidas de 166 países. Sobre este lenguaje se apoyan NumPy y pandas, librerías fundamentales para el cálculo numérico y la manipulación de datos tabulares. Para los modelos de aprendizaje profundo utilizaremos Keras, que complementa a Scikit-learn; en la encuesta de Kaggle aplicada a 23,859 profesionales de datos, los frameworks más usados fueron Scikit-learn (66%), Tensor Flow (53%) y Keras (44%).

El entorno de desarrollo y ejecución del modelo será local, con cada integrante trabajando en su IDE de preferencia (VS Code para la mayoría de los miembros). Nuestra elección de

desarrollar de manera local, en vez de usar tecnologías como Google Colab o la notebook de Kaggle, surge por practicidad y decisión técnica de llevar un control de versiones con GitHub en el que todos los integrantes puedan trabajar en sus ramas. También preferimos trabajar en archivos formato python (.py) sobre archivos en formato notebook (.ipynb), pues además de no requerir de un notebook para estos primeros, consideramos que era innecesario si al final los datos terminarían mostrándose en una interfaz.

En caso de requerir despliegue, Amazon Web Services (AWS) es el proveedor líder de nube a nivel mundial. De acuerdo con Synergy Research Group, AWS encabezó el mercado de servicios de infraestructura en la nube en el segundo trimestre de 2026 con 28% de participación, seguido de Microsoft con 20% y Google con 15%, además por la practicidad debido a las cuentas de AWS Academy con las que todo el equipo cuenta.

Para los datos climáticos usaremos la API de NASA POWER (Prediction Of Worldwide Energy Resources), una fuente confiable y gratuita respaldada por una agencia científica: ofrece datos con cobertura global y series de tiempo extensas, con variables de alta calidad y diversas opciones de acceso abierto, y antes de publicarlos, su equipo científico valida de forma independiente los datos de flujo solar y meteorológicos. Además, permite consultar datos con resolución horaria, diaria, mensual o climatológica, lo cual se adapta a las necesidades de nuestro análisis.

Para el control de versiones y la colaboración en el código utilizaremos GitHub, la plataforma de referencia en el desarrollo de software. Según su reporte Octoverse 2025, más de 180 millones de desarrolladores construyen en GitHub, y más de 36 millones de nuevos desarrolladores se unieron a la plataforma en el último año. Finalmente, para la gestión de documentación y archivos compartidos del equipo usaremos Google Drive, pues facilita el trabajo colaborativo en tiempo real entre los integrantes.

Actualmente los datos se están conservando de la siguiente forma: los datos originales entregados por el socio formador y generados por la máquina se encuentran en un Google Drive con acceso autorizado únicamente a miembros del Tecnológico de Monterrey. Este Google Drive está administrado por los profesores de la materia. La copia de los datos que está siendo trabajada y limpiada se almacena de forma local en las computadoras del proyectos, no se genera

una copia remota en Github para poder mantener la privacidad y seguridad de las mismas. La forma de generar los datos es teniendo los originales y ejecutando los archivos de anonimización de los datos. De esta manera podemos trabajar y limpiar los datos manteniendo su seguridad en todo momento.

Link del repositorio: https://github.com/EmilioQuinonez/VACAS_IA

Tamaño de la muestra (Cochran con ajuste finito):

- El tamaño de la muestra se calculó con la fórmula de Cochran, $n_0 = Z^2 \cdot p \cdot (1 - p) / e^2$. Se usó 95% de confianza ($Z \approx 1.96$), un margen de error de 5% y $p = 0.5$, que supone la máxima variabilidad cuando no se conoce la proporción real. Esto da $n_0 \approx 384.16$. Después se aplicó el ajuste para población finita, $n = n_0 / (1 + (n_0 - 1) / N)$, donde N es el total de registros. Como N es grande, el ajuste cambia poco y la muestra final quedó en 384 registros.

Muestreo estratificado:

- Para elegir los registros se usó muestreo estratificado, donde cada vaca (id_vaca) forma un grupo, de modo que cada vaca aporta a la muestra en proporción a su peso en el dataset. El peso de cada vaca es su proporción del total (conteo de la vaca / N), y el número de registros que le corresponde es ese peso multiplicado por el tamaño de la muestra, tomando la parte entera (conteo de la vaca * tamaño de la muestra / N). Los lugares que sobran para llegar a 384 se asignan, uno por uno, a las vacas con mayor residuo en esa división (método de restos mayores). Dentro de cada vaca, los registros se eligieron al azar y sin reemplazo, con semilla fija (42) para poder repetir el proceso.

Separación en train(sub separación en train y val con k-fold) y test:

- Primero se apartó el 20% de los datos como conjunto de pruebas (77 registros). Se reserva para la evaluación final y no se usa para entrenar ni validar. El 80% restante (307 registros) es el conjunto de entrenamiento. Se volvió a dividir con k-fold cross validation con k = 5, de modo que en cada fold unos 245 registros entrenan y unos 62 validan. Cada registro se usa como validación una vez.

Link a los archivos en repositorio: https://github.com/EmilioQuinonez/VACAS_IA/tree/develop/src/RETO_DATOS

Big Data:

a. En base al objetivo que se busca conseguir y al volumen de datos y su acceso, no es necesario utilizar un enfoque orientado a Big Data; en base a las 5 V's, no se cuenta con un gran volumen de datos (GB) y el acceso a estos no deben ser rápidos y consistentes. Tampoco se cuenta con mucha variedad de formatos.
b. Una situación donde nos convendría usar un enfoque en Big Data sería si se necesitara consumir datos de forma rápida y constante, por ejemplo, si el modelo siguiera aprendiendo mientras se está usando o si tuviéramos un volumen mayor de datos.

Modelo de flujo de los datos

Para observar el diagrama completo sobre el flujo de los datos, de click en el siguiente enlace: c

Referencias

1. Articsledge. (2026, 4 de octubre). Cloud market share 2026: AWS vs Azure vs Google Cloud. https://www.articsledge.com/post/cloud-market-share
2. Ashokumar, T. (2025, 11 de noviembre). GitHub's 2025 report reveals some surprising developer trends. Medium. https://medium.com/@eshwarbalamurugan/githubs-2025-report-reveals-some-surprising-developer-trends-b83eae70d45d
3. GitHub Staff. (2025, 28 de octubre). Octoverse: A new developer joins GitHub every second as AI leads TypeScript to #1. The GitHub Blog. https://github.blog/news-insights/octoverse/octoverse-a-new-developer-joins-github-every-second-as-ai-leads-typescript-to-1/

4. Kosman, C. (2025, 11 de agosto). Highlights from the Stack Overflow Developer Survey 2025 (vs 2024). 1000.software Substack. https://1000software.substack.com/p/highlights-from-the-stack-overflow
5. NASA Earthdata. (s.f.). The POWER of Earth science data. National Aeronautics and Space Administration. Recuperado el 20 de octubre de 2026, de https://www.earthdata.nasa.gov/news/feature-articles/power-earth-science-data
6. Pepy. (s.f.). numpy [Estadísticas de descargas de PyPI]. Recuperado el 20 de octubre de 2026, de https://pepy.tech/projects/numpy?timeRange=threeMonths&category=version&includeCIDownloads=true&granularity=weekly&viewType=line&versions=Total%2C2.*%2C1
7. Sparks, A. H. (s.f.). get_power: Get NASA POWER data from the POWER API [Documentación del paquete nasapower para R]. r-packages.io. Recuperado el 20 de octubre de 2026, de https://r-packages.io/packages/nasapower/get_power